28.01.2026

Klasyfikacja zmian na podstawie cech kształtu

Mammo grafia

podsumowanie projektu

Koło Naukowe AI Med

Zespół delta: *Urszula Klimczak, Konrad Zatorski, Filip Latawiec, Natalia Czop, Zofia Kąkolewicz, Karyna Rudenko*

Cel projektu i ograniczenia

Cel: sprawdzić, ile da się wyciągnąć z samego kształtu (mask-only) dla predykcji benign vs malignant

Ograniczenie: brak tekstur → mniej informacji niż “pełna radiomika”, polegamy na maskach binarnych

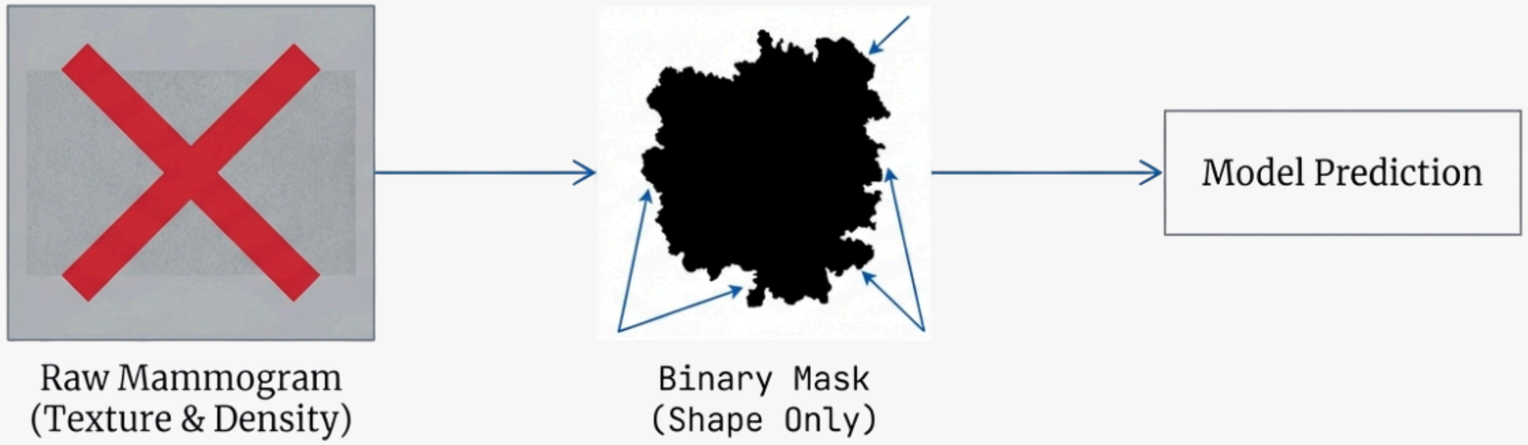

Dane i etykiety

Liczba rekordów: 1664

Klasy: BENIGN 54% vs MALIGNANT 46%

BI-RADS: mocno niezbalansowany (klasa 1 praktycznie nie istnieje, dominuje ciężka do klasyfikacji klasa 4)

Class Distribution

Class	Count	Distribution	Percentage
BENIGN	901		54.15%
MALIGNANT	763		45.85%

Assessment Distribution

BI-RADS Score	Count	Distribution	Percentage
0	162		9.74%
1	3		0.18%
2	89		5.35%
3	358		21.51%
4	689		41.41%
5	363		21.81%

Pacjenci i leakage

888 pacjentów:

- **266** badanych **raz**
- **622** badanych **więcej razy**

Niewłaściwy podział (Random Split) → ryzyko Data Leakage

Wniosek: Zastosowanie podziału Patient-Aware (StratifiedGroupKFold)

Number of tests performed	Number of patients
1	266
2	561
3	16
4	26
5	4
6	12
7	1
12	1
13	1

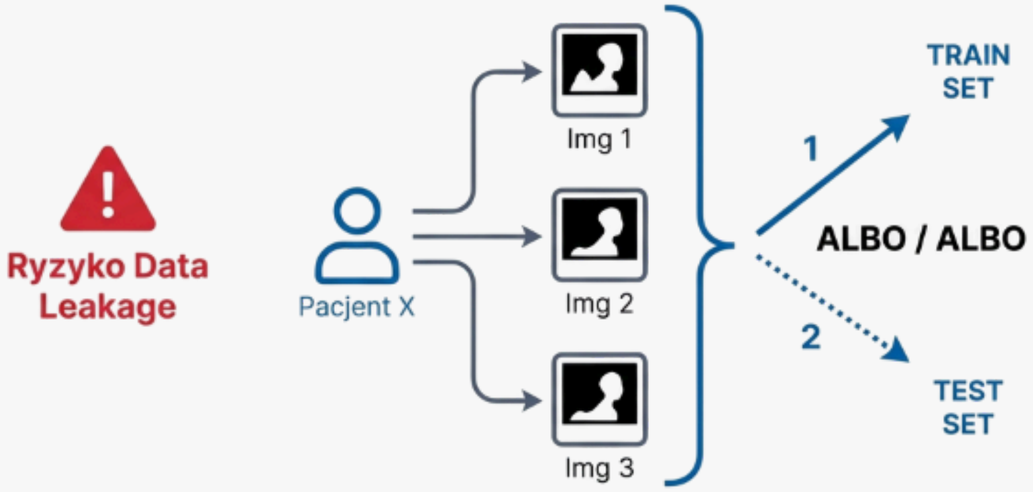

Pipeline end-to-end

Preprocessing

Metoda:

- **Konwersja do binarnej maski** (True/False)
- **Wypełnianie dziur** (binary_fill_holes)
- **Connected components →** zostawiamy największą zmianę

Orginal (Raw)

Preprocessed

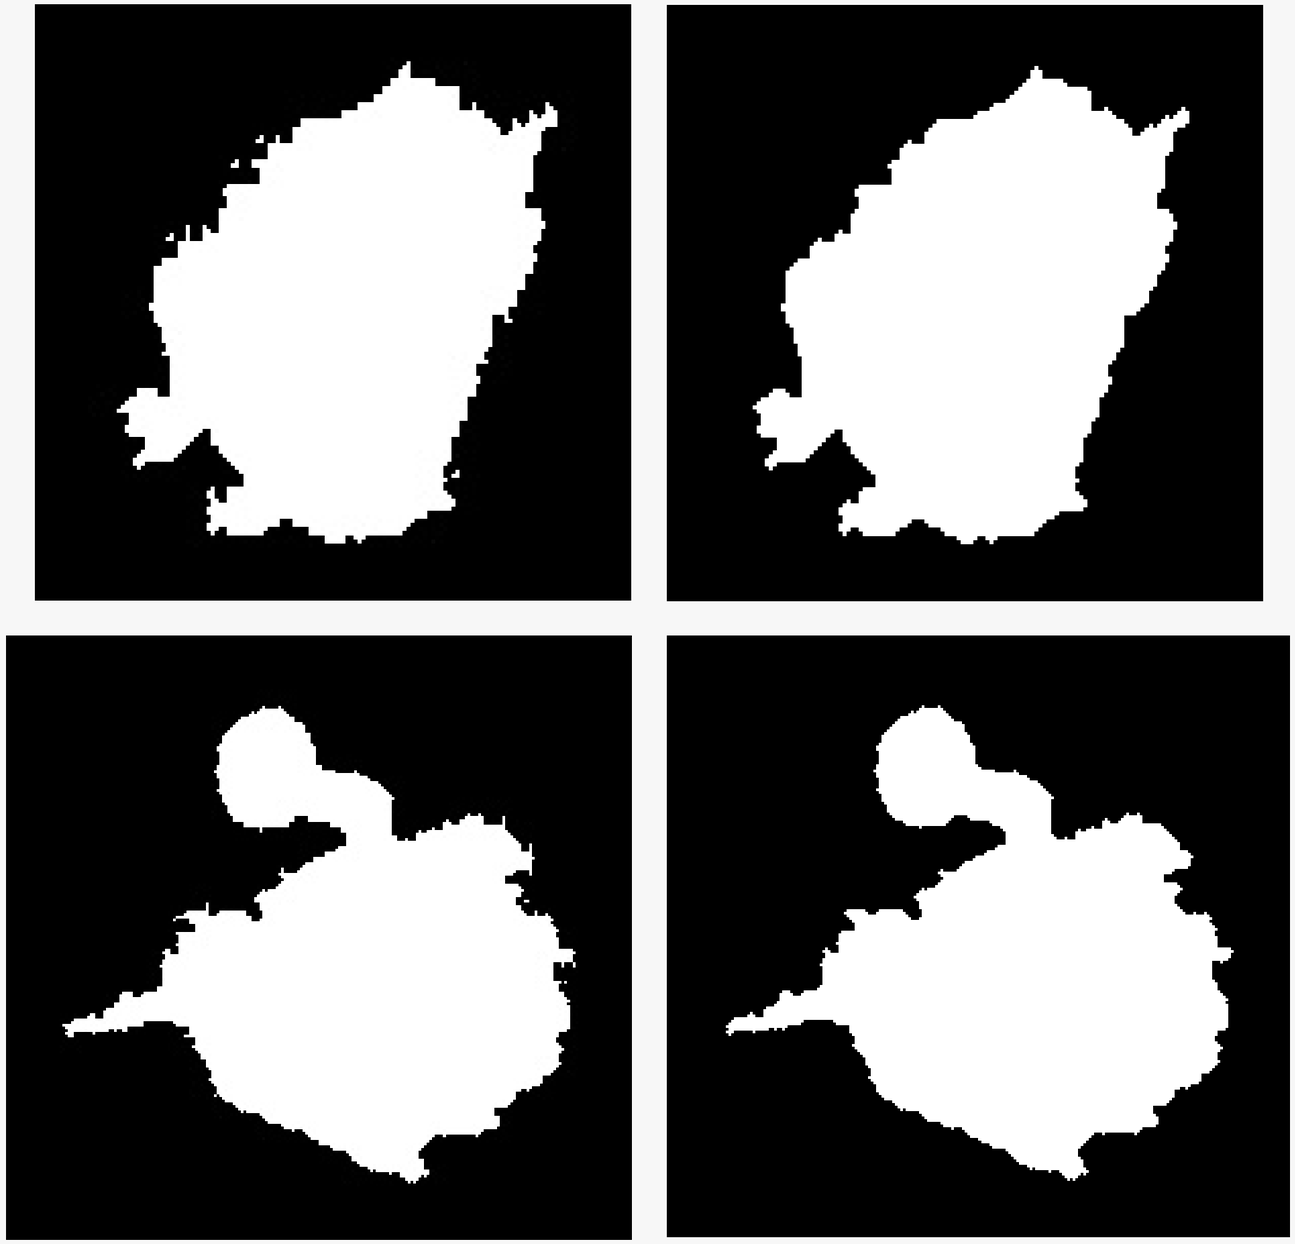

Feature extraction

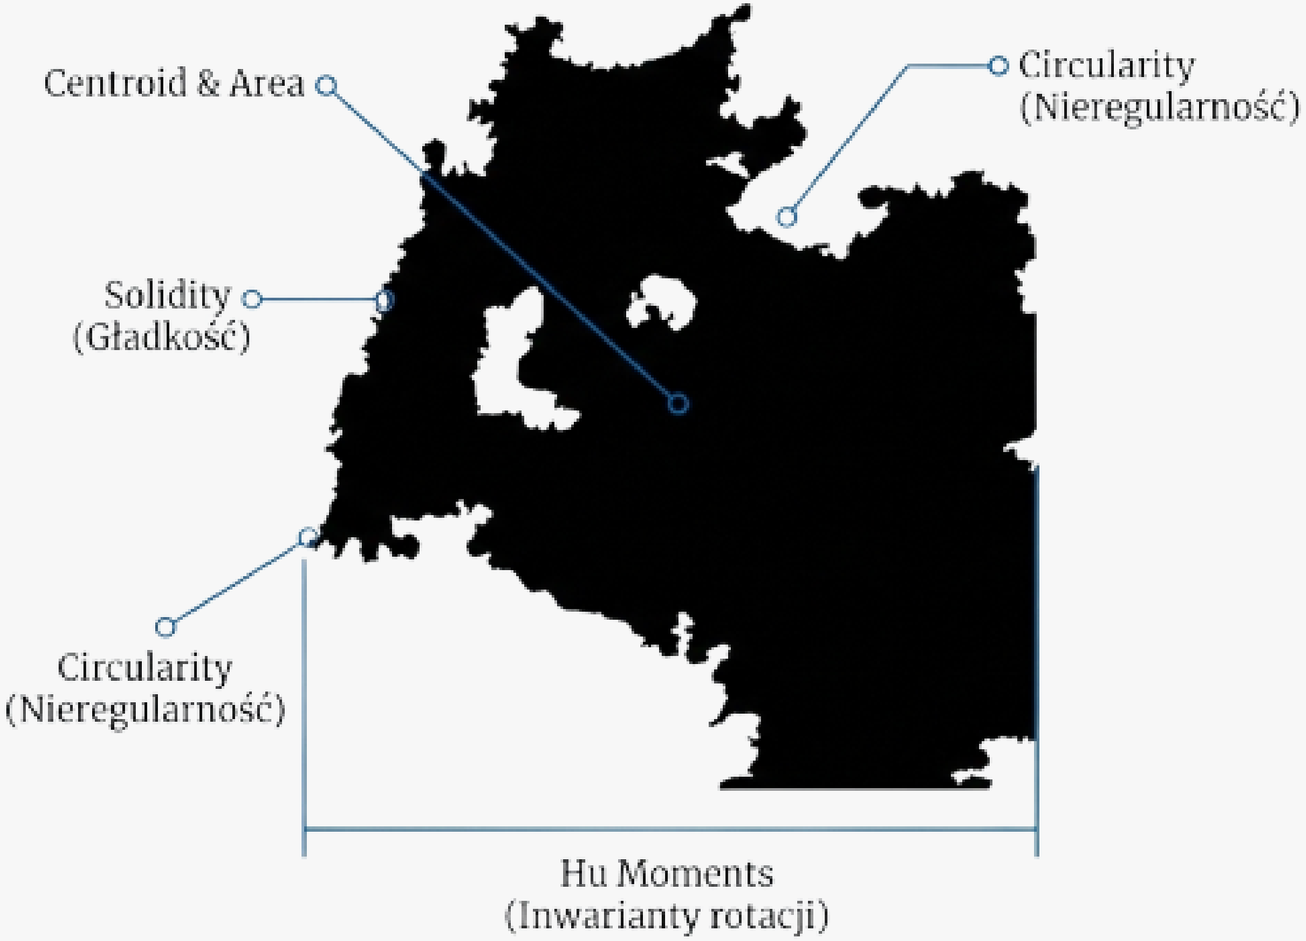

Geometria (Rozmiar / skala):
Area, Perimeter, Equivalent Diameter

Morfologia (Kształt/ brzeg):
Circularity, Solidity, Eccentricity, Extent, Irregularity

Inwarianty:
Hu Moments (log-transform)

Co oznaczają kluczowe cechy

Kolistość (Circularity)
1 = idealny okrąg. Spada przy poszarpanych brzegach.

Zwartość (Solidity)
Mierzy gładkość brzegu (stosunek pola do otoczki wypukłej).
~1 = gładki obrys, spada przy wcięciach/spikulach.

Mimośród (Eccentricity)
0 = koło, rośnie przy wydłużeniu elipsoidalnym.

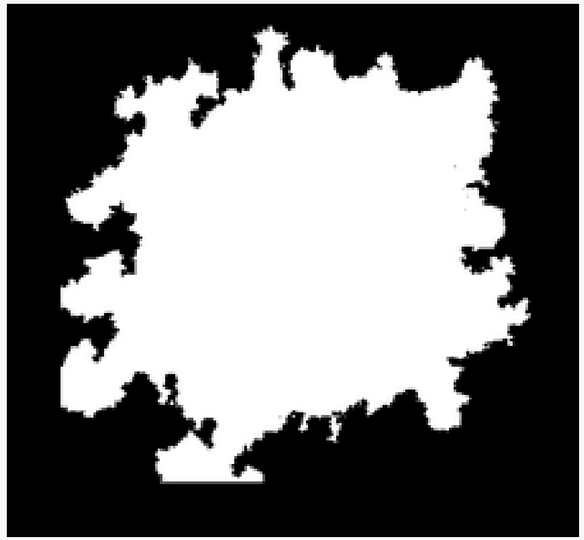

Geometria

- względne pole powierzchni (relative area)
- obwód (perimeter)
- współczynnik wypełnienia (extent)

Momenty Hu
Niezmienniki (invariants), odporne na obrót/skalę/przesunięcie. Transformowane logarytmiecznie.

EDA: korelacje i redundancja

Analiza: Macierz korelacji Spearmana (odporne na outliery)

Wnioski:

- **Wiele cech rozmiaru** (Area, Perimeter, Diameter) **jest prawie identycznych** (redundancja), co oznacza że niosą tę samą informację.
- Potrzebujemy selekcji cech, żeby nie dublować informacji

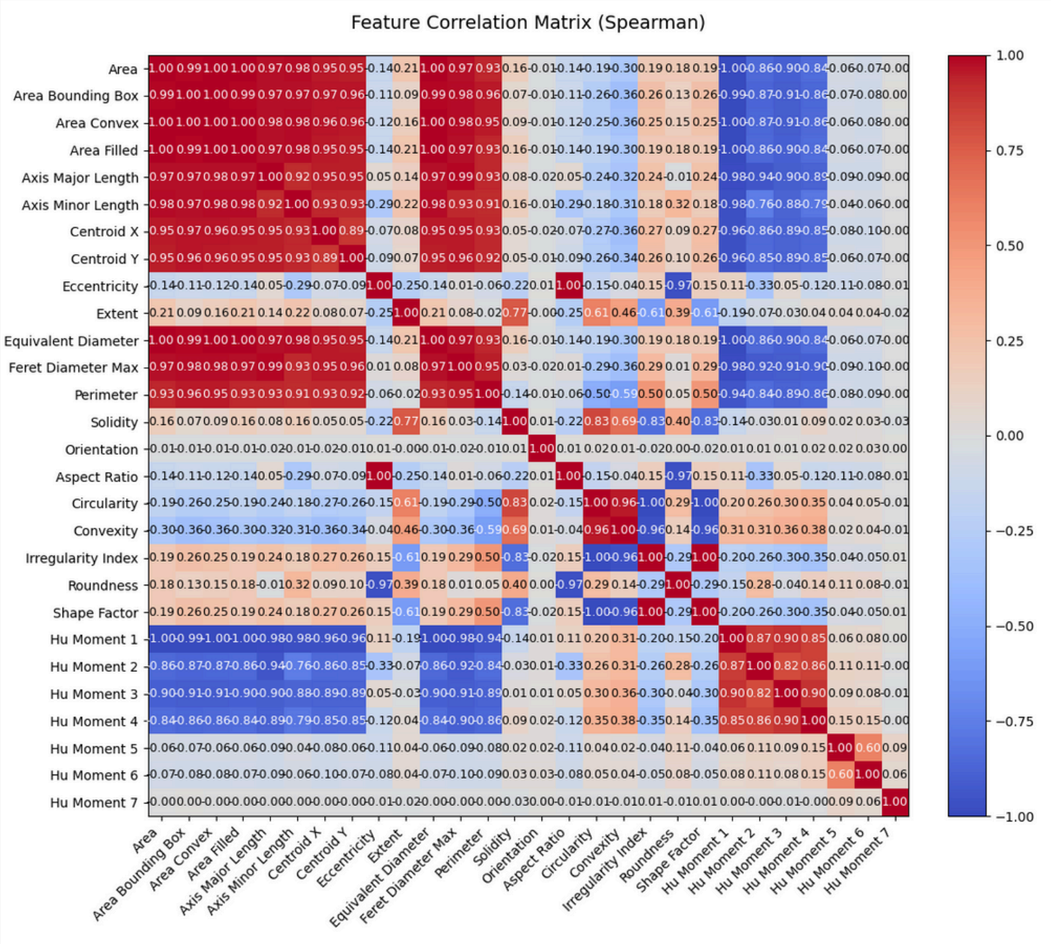

Selekcja cech: filtr korelacyjny

Strategia: Usunięcie cech o korelacji Spearmana > 0.90

Efekt: Zredukowany, ortogonalny zestaw cech, zapobieganie przeuczeniu (overfitting), stabilniejsze modele.

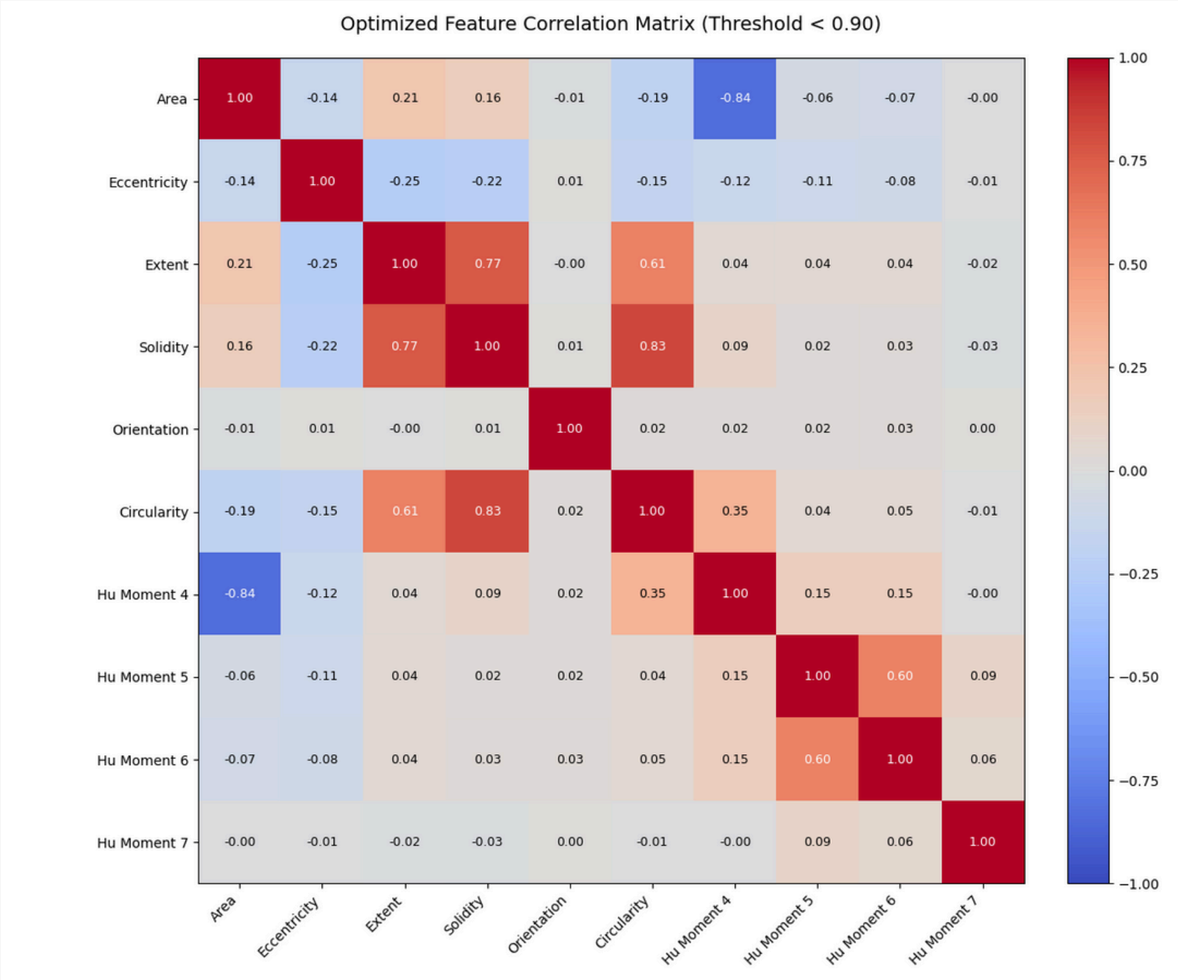

Separowalność cech

Wybrane cechy pokazują częściową separację benign vs malignant.
Zmiany złośliwe: niższa solidity, niższa circularity
Zmiany łagodne: wartości bliskie 1.0, zwarte, owalne formy

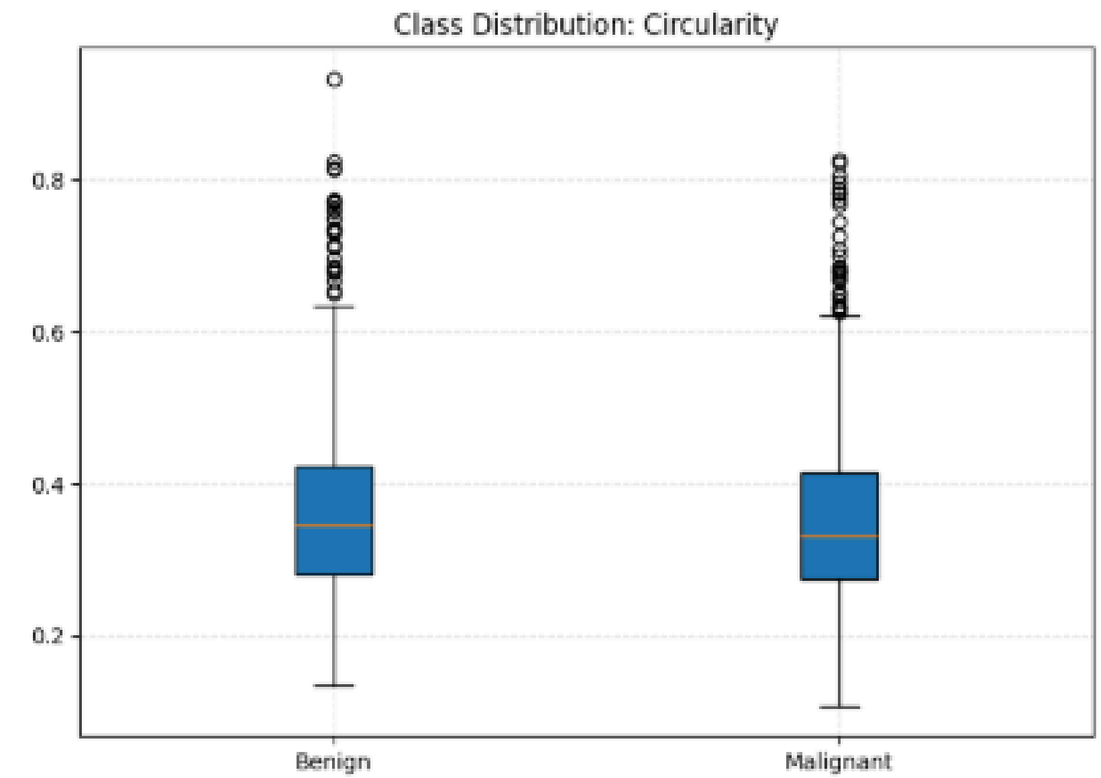

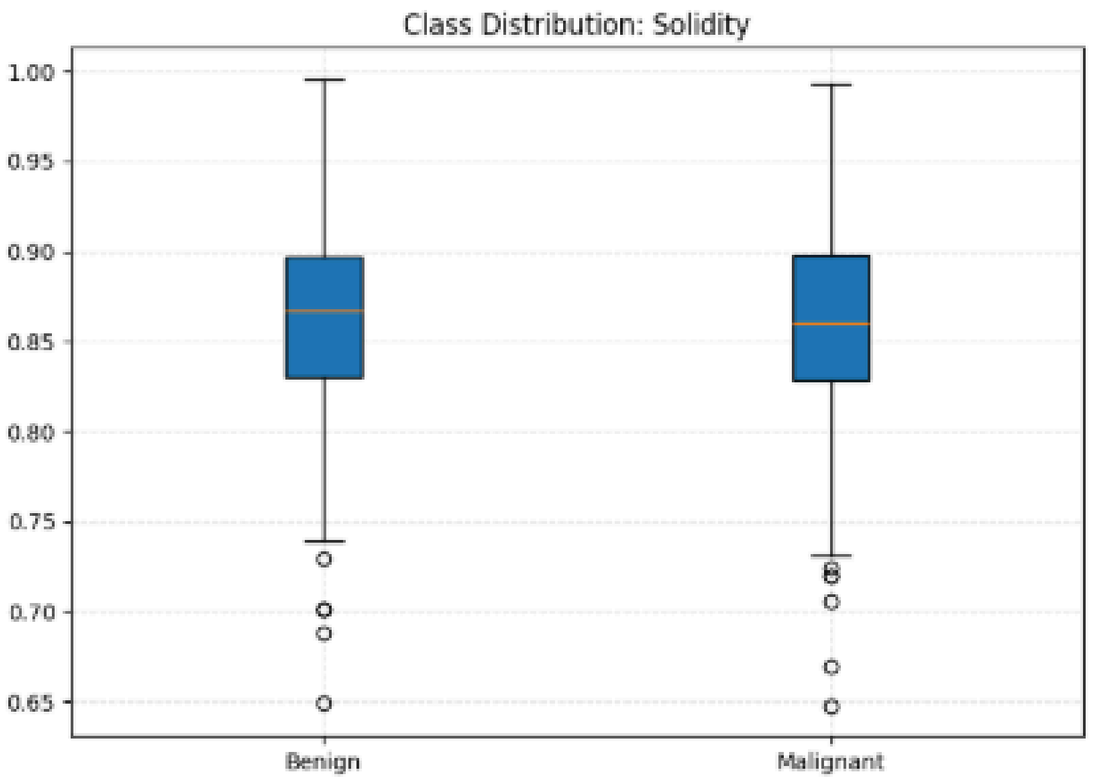

Resize/standaryzacja

Decyzja: Brak skalowania na etapie ekstrakcji cech.

Resize może zniekształcić krawędzie i tracić informacje o spikulach (skalowanie do niskich rozdzielczości np. 224x224) → wpływa na cechy oparte o obwód.

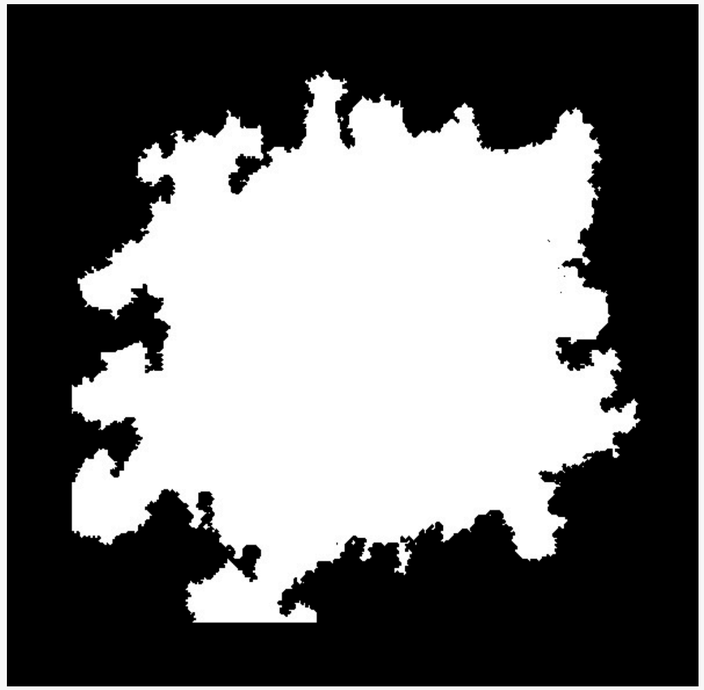

Orginal (Detail Preserved)

Resized (Detail Lost)

Radiomics mask-only

Radiomics “klasyczne” = shape + first-order + texture

Mask-only → zostaje głównie shape

Nie mamy tekstur / intensywności, więc interpretacja jest ograniczona

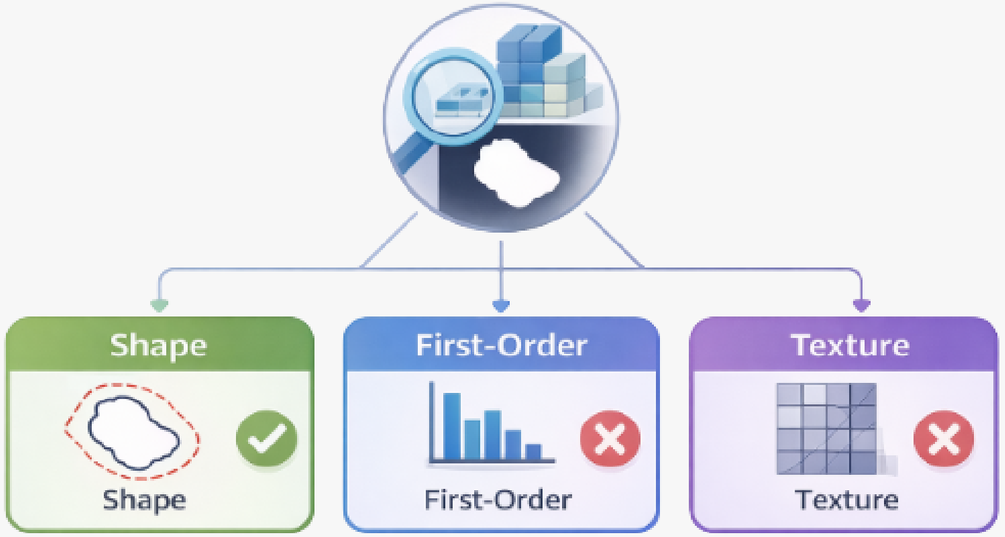

Finalny zestaw cech

Size: Retative Area

Shape: Eccentricity, Extent

Boundary: Circularity, Solidity

Invariants: Hu 4, Hu 5, Hu 6, Hu 7

Cecha (PL)	Feature (EN)	Opis
Mimośród	Eccentricity	Określa, jak bardzo kształt odbiega od idealnego koła (0 = koło, 1 = linia).
Zwartość	Solidity	Mierzy gładkość brzegu (stosunek pola obiektu do pola jego otoczki wypukłej).
Współczynnik wypełnienia	Extent	Stosunek pola powierzchni obiektu do pola prostokąta opisującego (bounding box).
Kolistość	Circularity	Miara podobieństwa obiektu do koła oparta na stosunku pola do obwodu.
Względne pole powierzchni	Relative Area	Znormalizowana wielkość obiektu w odniesieniu do całego obrazu.
Momenty Hu 4-7	Hu Moments 4-7	Zestaw inwariantów opisujących kształt niezależnie od jego skali, pozycji i obrotu.

Strategia Walidacji

Stratified Group K-Fold (n_splites = 5)

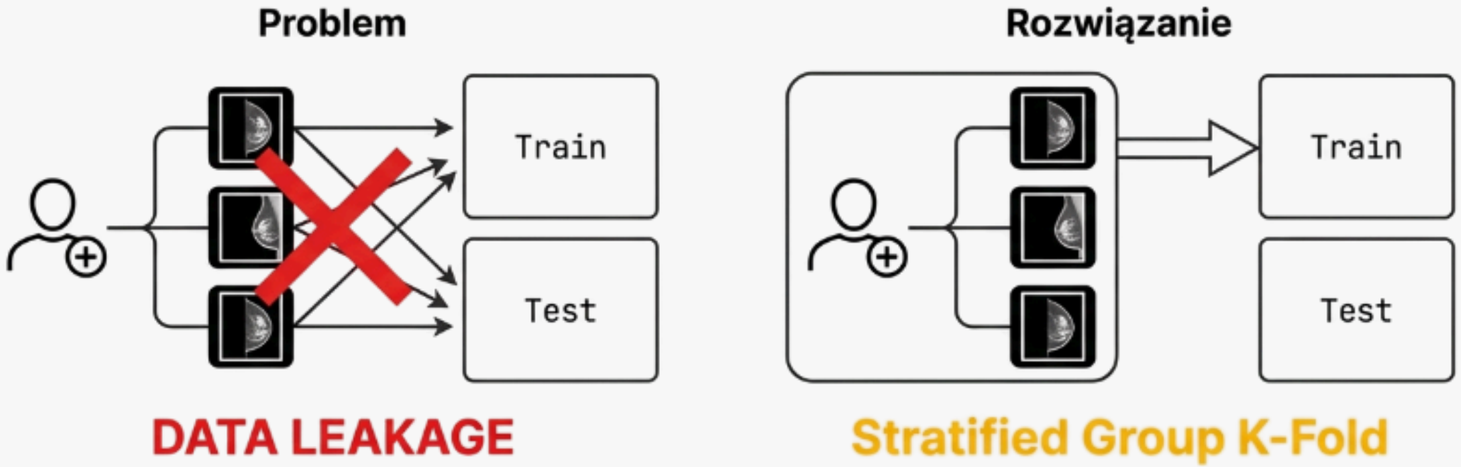

Stratified
Zachowuje proporcje klas (Benign/Malignant) w każdym foldzie. Kluczowe przy niezbalansowanych danych medycznych

Group (Patient-Aware)
Gwarantuje izolację pacjenta. Wszystkie zdjęcia tego samego pacjenta trafiają tylko do zbioru treningowego LUB testowego. Eliminuje Data Leakage.

Matryki:

Mean ± std (Accuracy, ROC-AUC, F1)

Modele: baseline i porównanie klasyków

Modele: Logistic Regression (baseline), SVM RBF, RandomForest, kNN

Metodyka: 5-Fold Stratified Cross-Validation, Grid Search Hyperparameter Tuning

Metryki, które raportujemy: Accuracy**,** Precision / Recall / F1 / ROC-AUC (z CV)

Modele: baseline i porównanie klasyków – Accuracy

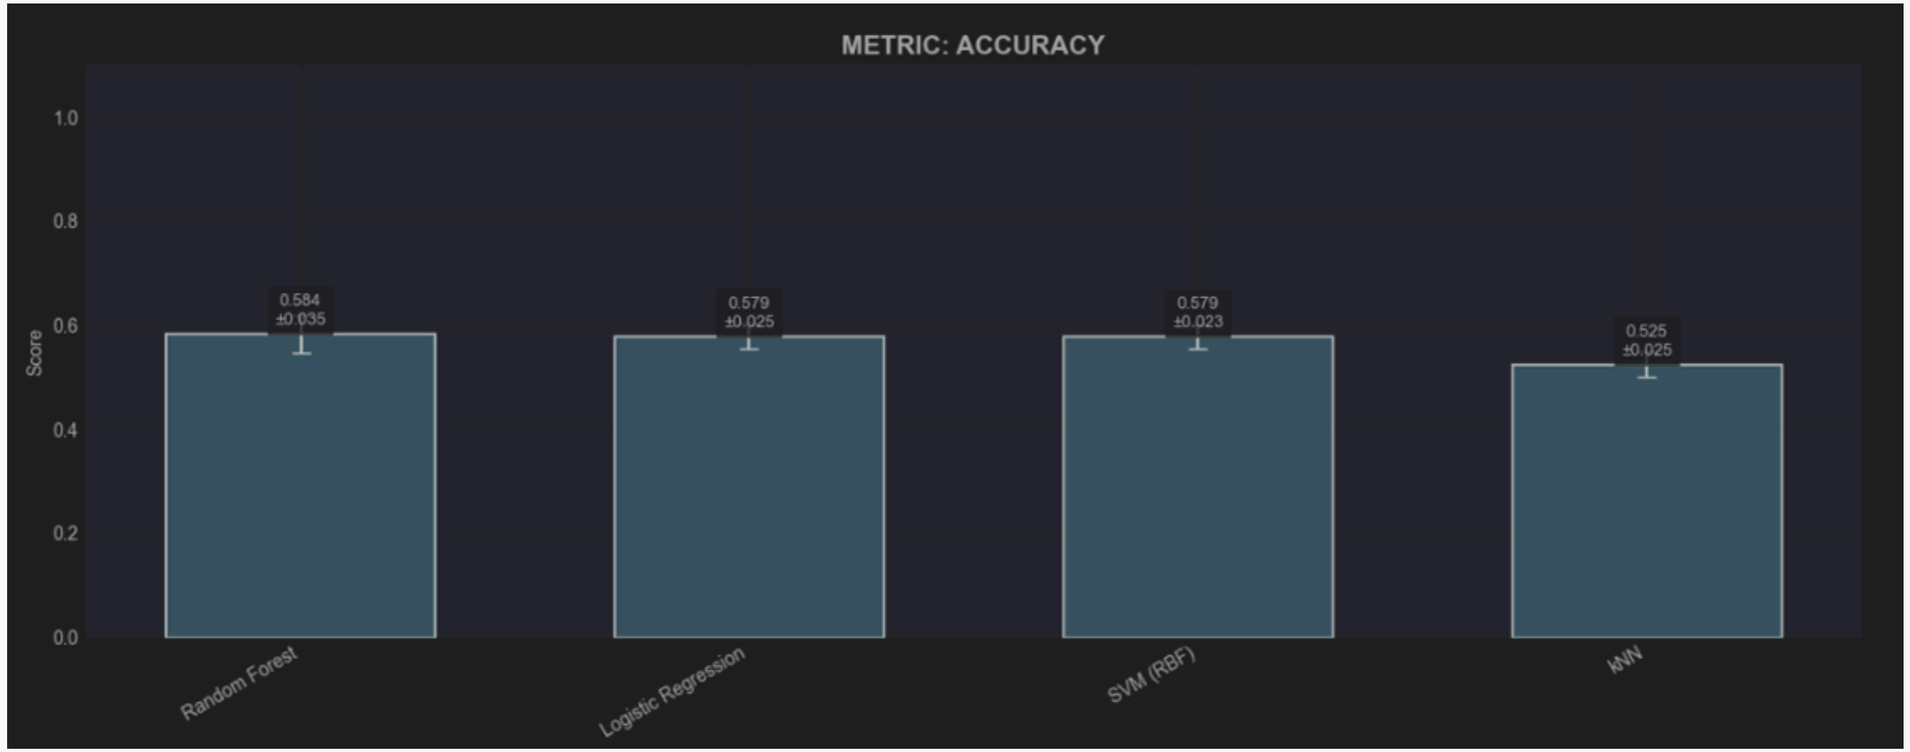

Modele: baseline i porównanie klasyków – Precision

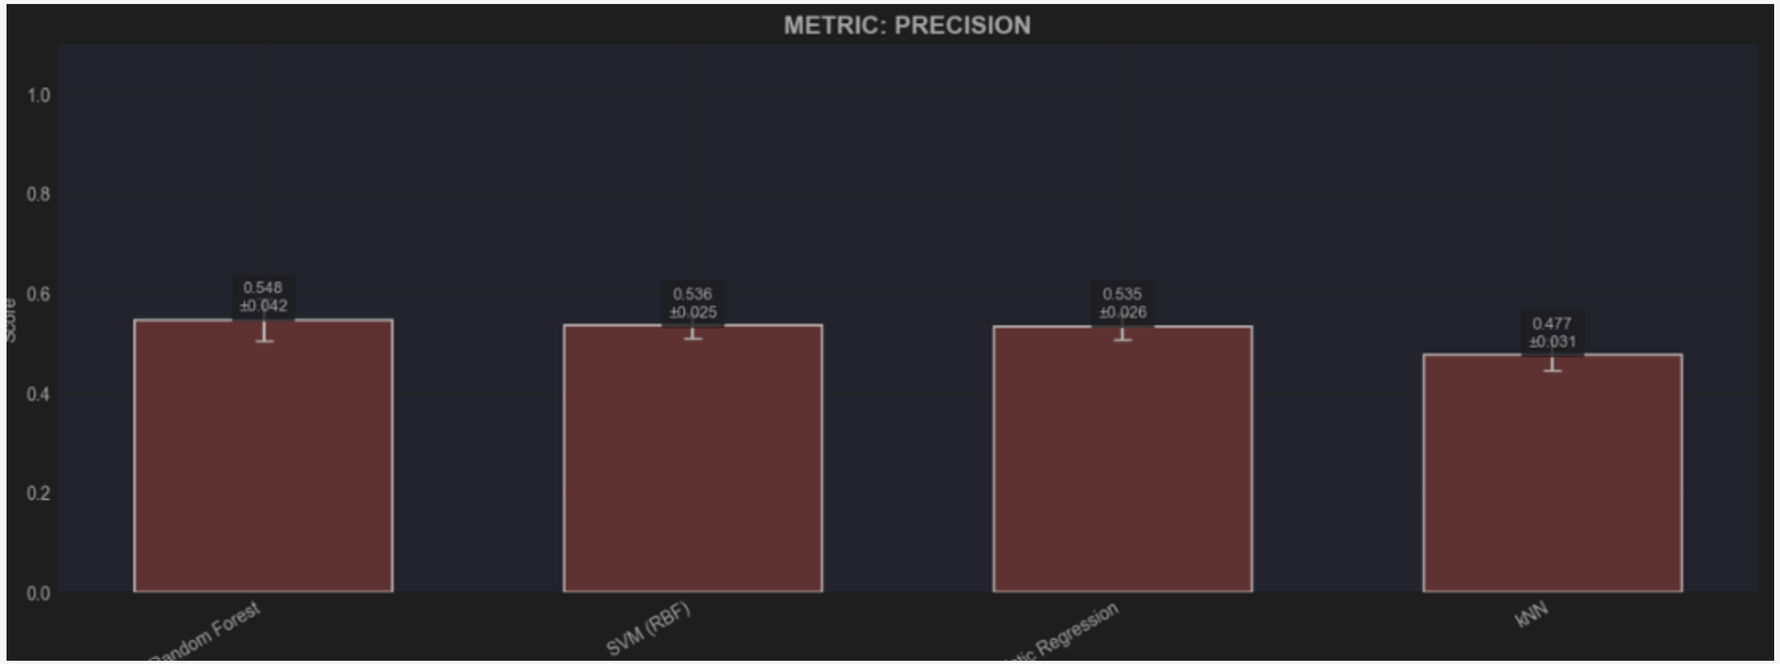

Modele: baseline i porównanie klasyków – Recall

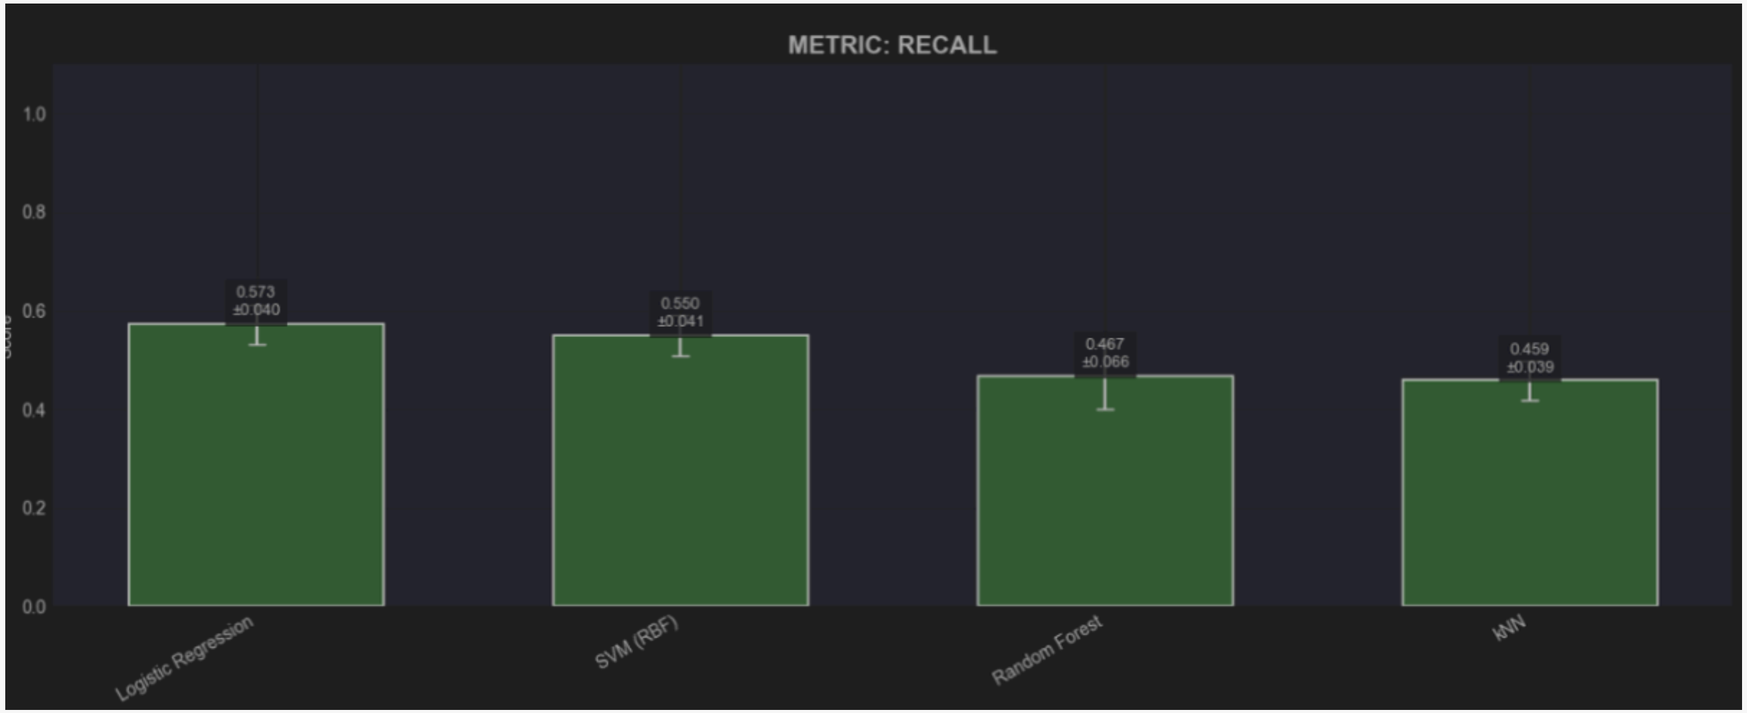

Modele: baseline i porównanie klasyków – F1 Score

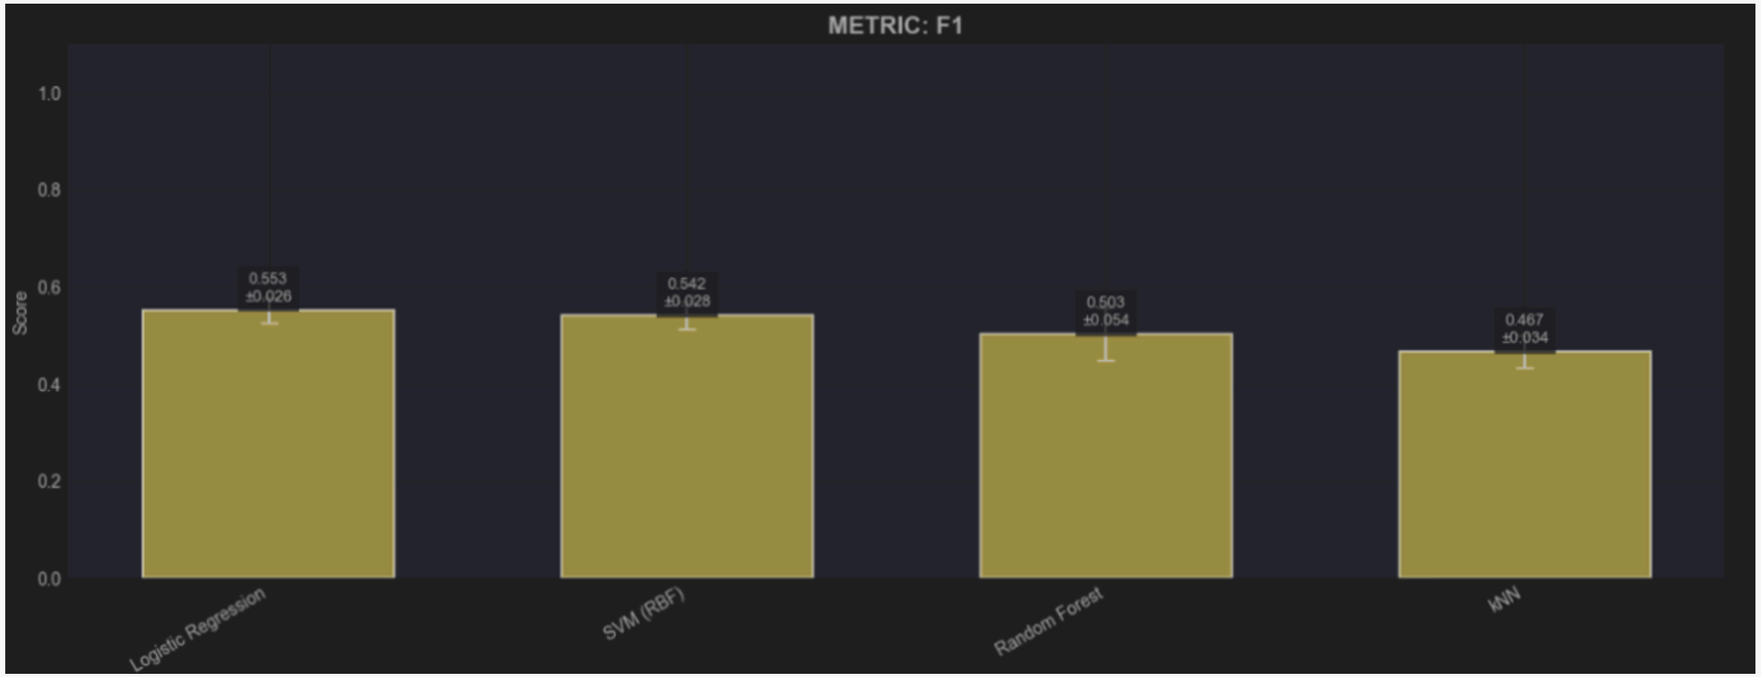

Modele: baseline i porównanie klasyków – ROC AUC

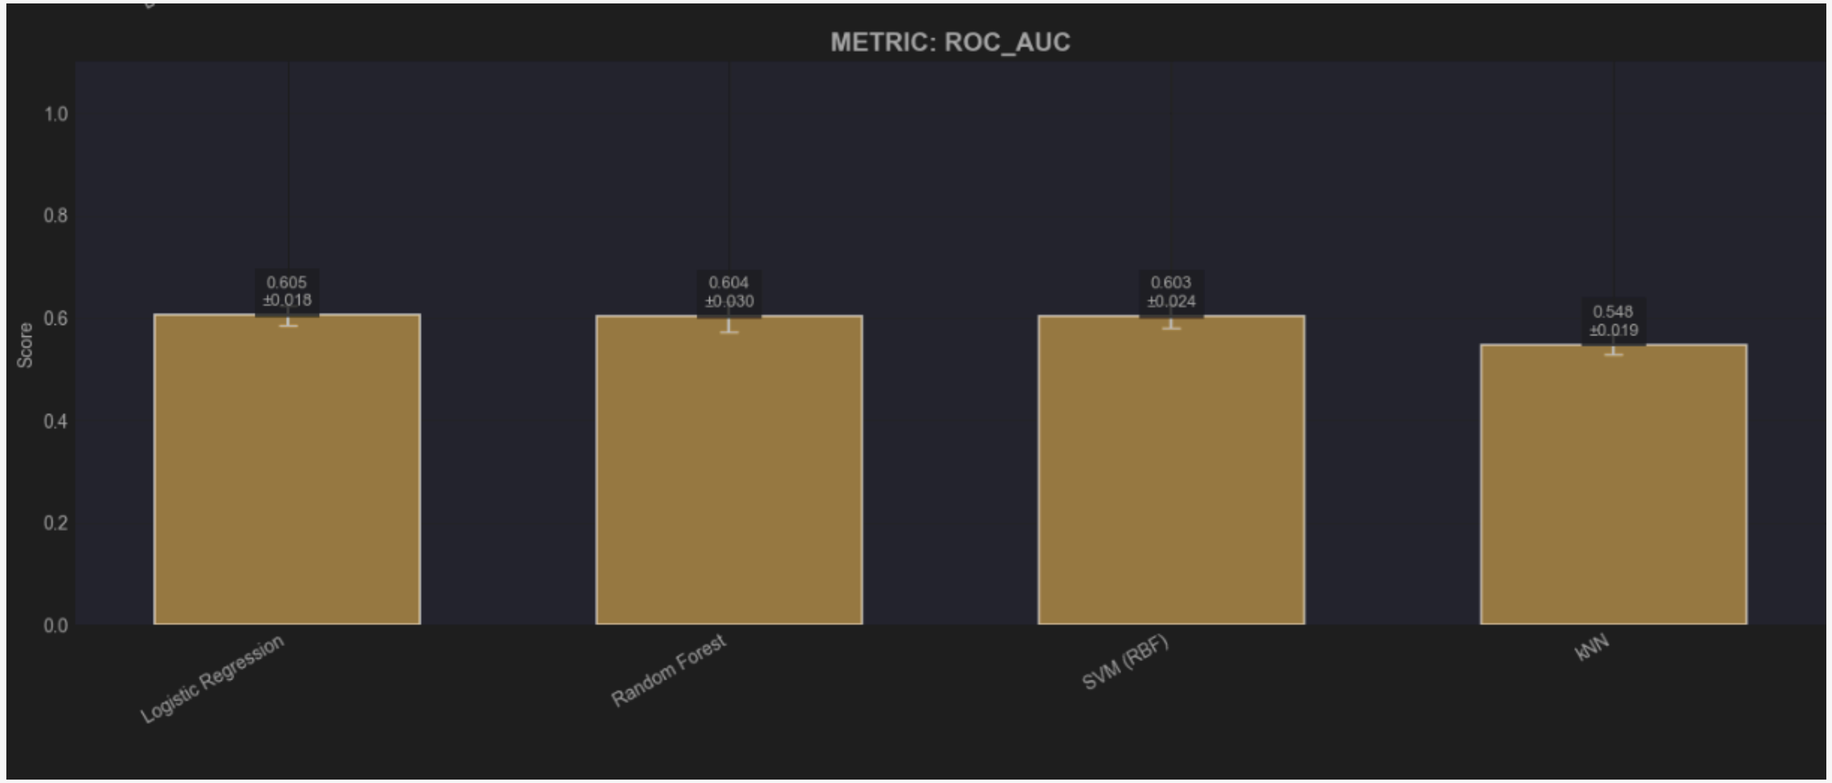

Modele: baseline i porównanie klasyków – ważność cech

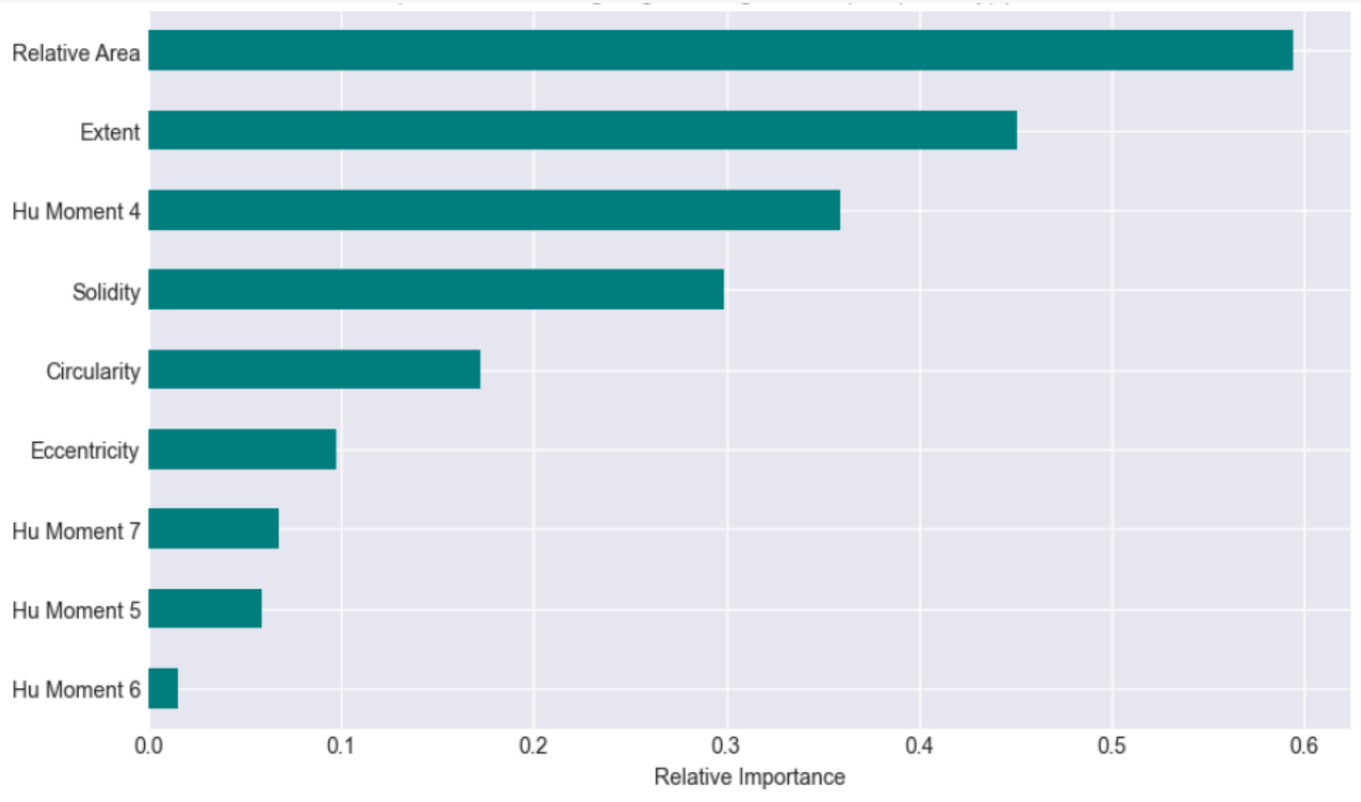

Top Predictors:

1. Relative Area
2. Extent
3. Hu Moment 4
4. Solidity

Błędy:

False Negatives: 71

False Positives: 65

Protokół ewaluacji + podsumowanie wyników

Walidacja: Stratified CV + patient-aware split

Model	F1-Score	Precision	Recall	ROC-AUC
SVM (RBF)	**0.5605**	0.5428	**0.5824**	0.5978
Logistic Regression	0.5527	0.5425	0.5644	**0.6085**
Random Forest	0.4754	0.5293	0.4323	0.5802
kNN	0.4657	0.4814	0.4520	0.5197

Safety Champion: SVM
Najlepszy balans Recall (czułości), kluczowy w medycynie do minimalizacji ryzyka przeoczenia choroby.

Stability Champion: Logistic Regression
Najlepsza generalizacja i najwyższe AUC, model najbardziej odporny na szum.

Eksperyment Shape + Assessment

Shape-only
Tylko cechy geometryczne z maski

Assessment-only
Wynik BI-RADS (opinia radiologa)

Hybrid
Kształt + BI-RADS

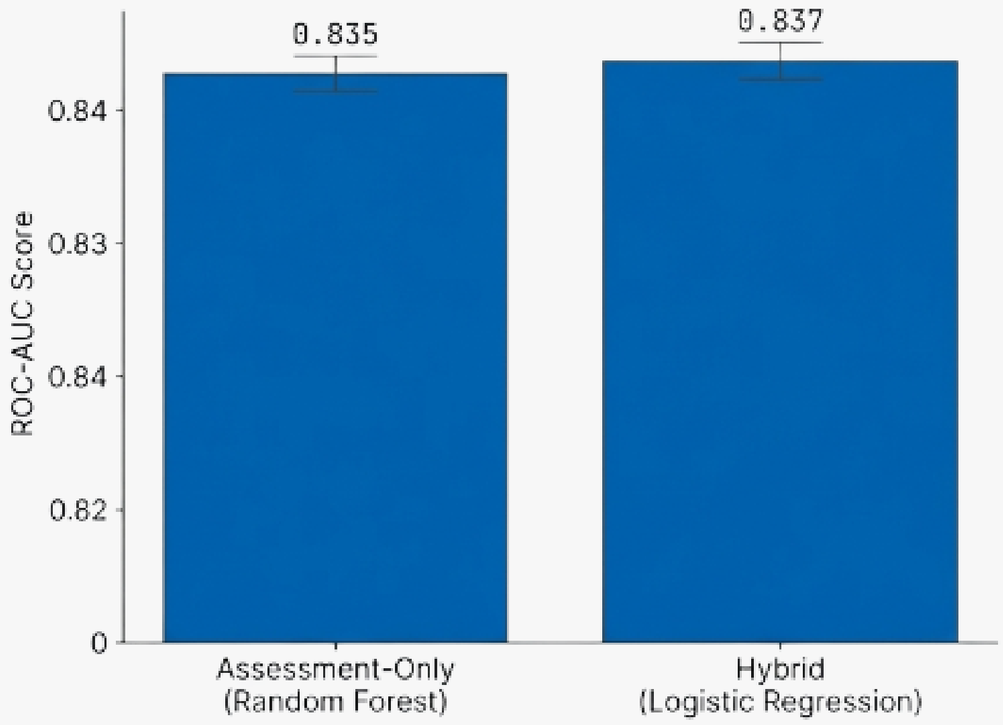

Wyniki:
Dodanie cech kształtu do oceny radiologa utrzymuje wysokie wyniki AUC. W przypadkach granicznych (BI-RADS 4), komputerowa analiza kształtu działa jako “tie-breaker”

Error analysis: co myli model (FN/FP)

FN = największe ryzyko (malignant → benign)
"Geometric mimicry": Niewykryte nowotwory "udają" zmiany łagodne - są bardziej okrągłe i mają gładsza brzegi. To biologiczny kamuflaż dla modelu opartego tylko na geometrii.

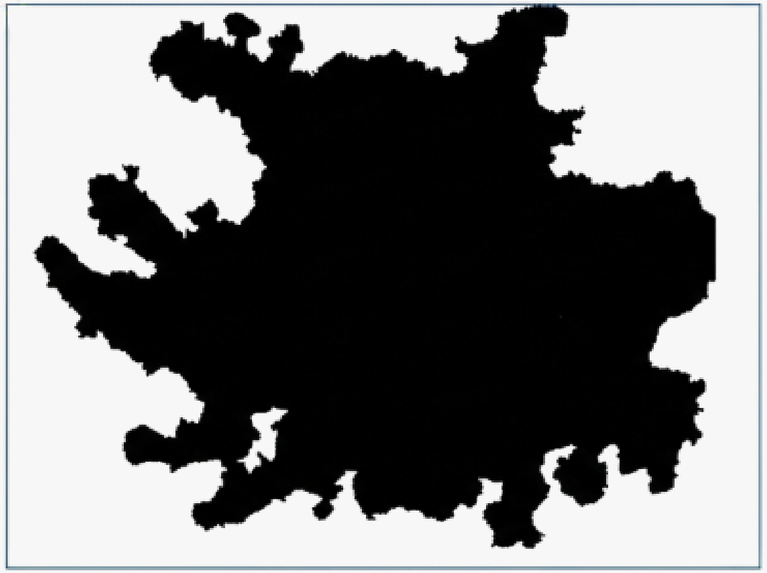

Feature	False Negatives (Avg)	Global Malignant (Avg)
Circularity	0.40	0.35
Solidity	0.87	0.86

False Negative (Mimikra)

Error analysis: Moment Hu 7

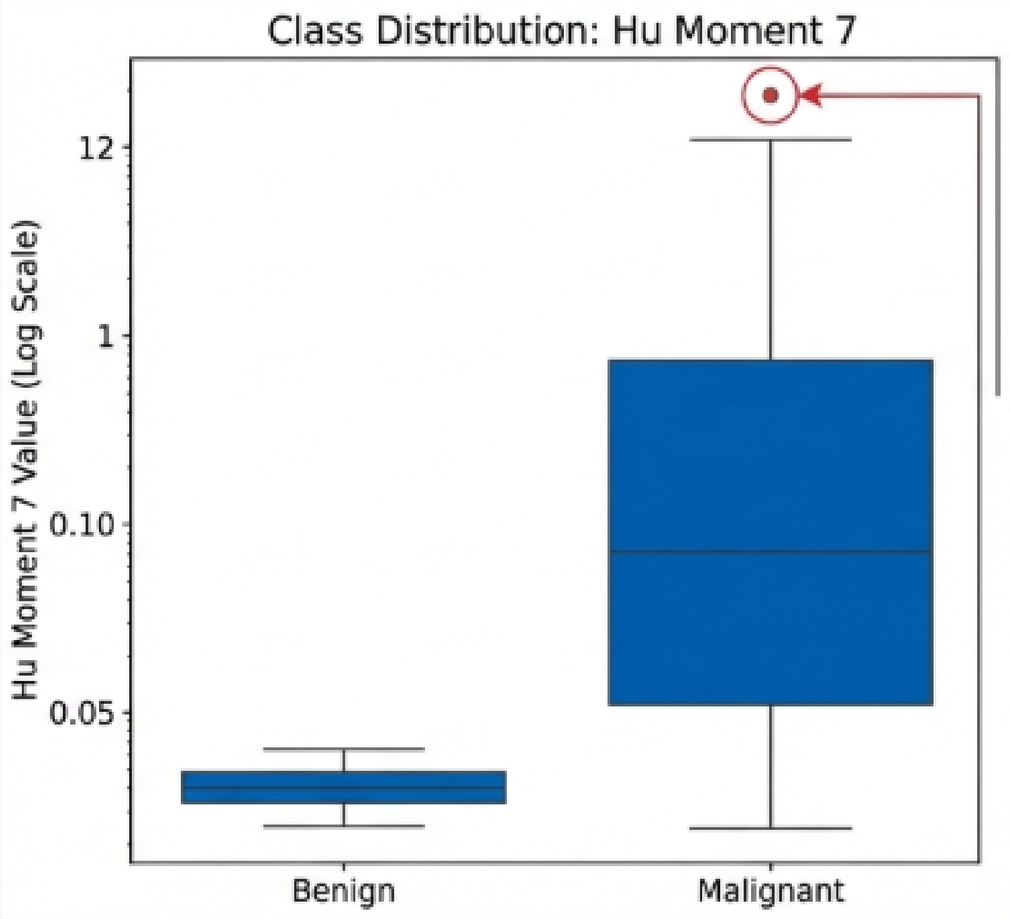

False Negative Average: 11.98

Global Average: 0.05

Moment Hu 7 wychwytuje złożoną asymetrię, niewidoczną dla standardowych miar. Tak duża różnica wartości w błędnie sklasyfikowanych przypadkach sugeruje, że ten parametr jest kluczem do wykrywania nowotworów w tym przypadku.

Wnioski + ograniczenia

Wnioski:

- mask-only daje sensowny sygnał z kształtu
- circularity/solidity + Hu momenty są kluczowe
- redukcja redundancji cech poprawia stabilność (z 28 do ~12 kluczowych cech)

Ograniczenia:

- brak tekstur/intensywności: ‘Mask-only’ ignoruje gęstość tkanki - kluczową dla radiologa
- BI-RADS mocno niezbalansowany: utrudnia precyzyjną kalibrację
- Skala danych: 1664 obrazy to za mało dla CNN

Koniec!

Zespół delta:

Urszula Klimczak,
Konrad Zatorski,
Filip Latawiec,
Natalia Czop,
Zofia Kąkolewicz,
Karyna Rudenko