Przegląd metod klasyfikacji i sposobów analizy danych oraz analiza i porównanie podejść z literatury

Raport w ramach działalności koła naukowego AI Med

Autor: Konrad Zatorski

Użyte narzędzia: Google Scholar, Scopus, Notebook LM

Przegląd metod klasyfikacji i sposobów analizy danych oraz analiza i porównanie podejść z literatury.....1
Moje główne uwagi w przypadku naszego problemu..... 4
Krótkie zestawienie najlepszych tradycyjnych modeli Machine Learningowych użytych w przypadku badania mammografii.....5
Logistic Regression (LR) Classifier.....5
Support Vector Machines (SVM) Classifier.....5
Random Forest (RF) Classifier..... 6
K-Nearest Neighbours (KNN) Classifier.....6
Wydajność klasyfikatorów na cechach kształtu..... 7
Metody analizy wyników z klasyfikatorów.....8
Macierz pomyłek (Confusion Matrix).....8
Ocena progowania.....8
Regresja.....9
Moje rekomendacje co do modeli klasycznych.....10
Konwolucyjne sieci neuronowe - alternatywa w stosunku do klasycznych metod klasyfikacji.. 10
Opisy badań naukowych dot. wykorzystania modeli Deep Learningowych w klasyfikacji mammogramów:..... 11
1. Deep learning in mammography images segmentation and classification: Automated CNN approach..... 11
Cel artykułu..... 11
Użyte dane..... 11
Użyte modele..... 12
Wyniki..... 12
Wnioski..... 12
2. Breast Cancer Detection in Mammography Images: A CNN-Based Approach with Feature Selection.....12
Cel artykułu.....12
Użyte dane.....13
Użyte modele.....13
Wyniki..... 14
Wnioski..... 16
3. Feature fusion and Ensemble learning-based CNN model for mammographic image classification.....16
Cel artykułu.....16
Użyte dane.....17
Użyte modele.....17
Wyniki..... 17
Wnioski..... 18
4. Convolutional neural networks for mammography mass lesion classification..... 19
Użyte dane.....19

Użyte modele..... 19
Wyniki..... 20
Wnioski..... 20
Wykorzystanie modeli Deep Learningowych w literaturze - porównanie z klasycznymi modelami..... 21
Skuteczność klasyfikatorów na cechach kształtu - porównanie z podejściem Deep Learningowym..... 21
Źródła.....22
Analiza przy użyciu Notebook Deep Research.....23

Moje główne uwagi w przypadku naszego problemu

- Wysoka trafność modelu może być myląca – jeżeli klasa negatywna dominuje model może przestać w ogóle wykrywać przypadków pozytywnych.
- W naszym przypadku mamy w miarę zbalansowany zbiór danych (901 przypadków zmian łagodnych oraz 763 zmiany złośliwe).
- W diagnostyce medycznej kluczowa jest maksymalizacja wskaźników związanych bezpośrednio z bezpieczeństwem pacjenta – sensitivity i ROC – oraz minimalizacja występowania diagnoz Fałszywie Negatywnych (FN), być może kosztem zwiększenia występowania Fałszywych Pozytywów (FP).
- W literaturze naukowej występują dwa podejścia do problemu wykrywania raka piersi:
    - Klasyfikacja z użyciem tradycyjnych modeli ML – najpewniejsze i najprostsze w naszym przypadku podejście do problemu, wykorzystanie algorytmów do klasyfikacji wektorów cech, które zostały wcześniej zgromadzone z wykorzystaniem radiomicznych metod ekstrakcji danych z obrazów.
    - Wykorzystanie sieci konwolucyjnych CNN oraz innych modeli Deep Learningowych – cięższe wdrożenie, lecz lepsze wyniki – w naszym przypadku, gdy będziemy analizować mało skomplikowane obrazy może być to podejście zbyt wymagające w stosunku do potencjalnych zysków precyzji modelu.
- Wybór algorytmu w naszym przypadku jest ściśle powiązany ze strategią ekstrakcji cech. Sieci CNN dobrze radzą sobie na surowym obrazie, podczas gdy klasyczne modele opierają się przede wszystkim na analizie cech uzyskanych z wydobycia danych ilościowych z obrazów.
- W tradycyjnym podejściu radiomicznym, analiza cech kształtu wymaga precyzyjnej segmentacji guza. Po segmentacji, obliczane są wskaźniki geometryczne, które stanowią wektory wejściowe dla klasyfikatorów.
- W naszym przypadku kształt guza jest wyraźnie widoczny dzięki zastosowaniu zero-jedynkowej maski binarnej, co ułatwia analizę i ekstrakcję cech obrazów.

Krótkie zestawienie najlepszych tradycyjnych modeli Machine Learningowych użytych w przypadku badania mammografii

Logistic Regression (LR) Classifier

- Metoda klasyfikacji ceniona przez naukowców przez swoją prostotę.
- Oparta jest na funkcji logistycznej (sigmoidalnej), która przekształca dowolną wartość do przedziału (0, 1) i pozwala wyliczyć prawdopodobieństwo zakwalifikowania próbki do jednej z dwóch kategorii.
- Wymaga stosunkowo niewielu danych (poniżej 100 próbek) - w naszym przypadku nie jest to zaleta.
- W regresji logistycznej bardzo ważne jest pozbycie się wartości odstających w zbiorze danych.
- Dobrze radzi sobie, gdy relacje między cechami a diagnozą są w przybliżeniu liniowe. Ważne jest, aby cechy nie były ze sobą silnie skorelowane, współliniowość cech może prowadzić do błędnych wniosków i przypisanie zbyt dużych wag poszczególnym cechom.
- Zastosowanie regularyzacji L1 lub L2 redukuje ryzyko przeuczenia modelu
- Regularyzacja - wprowadzenie dodatkowych informacji lub ograniczeń do modelu, aby zapobiec nadmiernemu dopasowaniu poprzez karanie zbyt złożonych modeli.
- Jego ograniczeniem jest założenie liniowości cech, słabo radzi sobie ze złożonymi i nieliniowymi kombinacjami cech.
- Cechuje się wysoką interpretabilnością, czyli możliwością prześledzenia jak model doszedł do danej decyzji.
- Niezbędne skalowanie danych w celu implementacji modelu.
- Wniosek: dobry jako model bazowy, docelowo do zastąpienia przez lepszy model.

Support Vector Machines (SVM) Classifier

- Metoda polega na rozróżnieniu klas poprzez mapowanie danych na wielowymiarowej przestrzeni właściwości w sposób umożliwiających kategoryzację danych oraz znalezienie optymalnej hiperpłaszczyzny, która rozdziela i maksymalizuje margines między najbliższymi punktami danych z przeciwnych klas na podstawie analizy.
- Dobrze sprawdza się w przypadku dużej ilości cech w zbiorze danych.
- Działa szczególnie dobrze na średnich i dużych zbiorach danych – tak jak w naszym przypadku.
- Nadaje się do użycia w przypadku występowania nieliniowych relacji w danych.
- Charakteryzuje się wysoką skutecznością klasyfikacji raka piersi - na podstawie cech fizycznych w zestawie danych UCI osiągnął 98% skuteczności.
- Trening bardziej złożony obliczeniowo na dużych zbiorów danych w stosunku do innych modeli.
- Interpretacja wynikowego modelu jest trudniejsza w stosunku do innych modeli.

- Cechuje się bardzo wysoką czułością na strojenie hiperparametrów, co umożliwia znaczne zmniejszenie Fałszywych Negatywów (FN) poprzez strojenie parametrów pod Recall Score kosztem Accuracy Score – mówiąc prościej możemy zwiększyć wykrywalność przypadków złośliwych kosztem zakwalifikowania niektórych przypadków łagodnych jako złośliwe,
- Niezbędne skalowanie danych w celu implementacji modelu.
- Powszechnie i od wielu lat wykorzystywany w badaniach naukowych dot. wykrywania raka piersi.
- Wniosek: model warty wzięcia pod uwagę jako docelowy, szczególnie w przypadku, gdy zależy nam na wysokim Recall Score.

Random Forest (RF) Classifier

- Metoda polega na konstruowaniu wielu drzew decyzyjnych w czasie uczenia i generowaniu klasy, która jest dominantą klas poszczególnych drzew.
- Opiera się na agregacji drzew decyzyjnych, co zmniejsza ryzyko przeuczenia modelu w porównaniu z pojedynczym drzewem decyzyjnym.
- Ryzykowny dla małych próbek danych (poniżej 100), charakteryzuje się dużą wydajnością dla średnich zbiorów danych (powyżej 500 próbek).
- Podobnie jak SVM bardzo dobrze działa dla złożonych i nieliniowych zbiorów danych.
- Jest to najbardziej zrównoważony klasyfikator, osiąga stabilnie wysoki wynik AUC.
- Charakteryzuje się wysoką interpretabilnością co pozwoli na łatwiejszą analizę rozumowania modelu.
- Działa dobrze bez potrzeby skalowania danych.
- Wniosek: model warty wzięcia pod uwagę jako ten docelowy, najbardziej stabilny, efektywny i przewidywalny.

K-Nearest Neighbours (KNN) Classifier

- Metoda polega na zakwalifikowaniu danej próbki w oparciu o kategorię przypisaną jej k najbliższym sąsiadom. Podstawowym założeniem tej metody jest to, że próbki, które są blisko siebie, są do siebie podobne - należą do tej samej kategorii.
- Algorytm KNN cechuje się prostotą interpretacji wyników oraz szybkością trenowania modelu w przypadku niewielkiego zbioru danych.
- W przypadku bardzo dużych zbiorów danych czas przewidywania może ulec znacznemu wydłużeniu. Co więcej, dla dużej bazy danych może stać się on kosztowny obliczeniowo i pamięciowo, ponieważ model do zakwalifikowania nowej próbki musi mieć wgrany cały zbiór danych treningowych.
- Działa dobrze w przypadku małej ilości cech kształtu.
- KNN słabo radzi sobie ze skomplikowanymi wektorami cech.

- W nowoczesnej diagnostyce jest rzadko stosowany jako docelowy model.
- Może zostać wykorzystany jako baseline, ze względu na prostotę jego działania.

Wydajność klasyfikatorów na cechach kształtu

- W przypadku modeli klasycznych cechy kształtu (zwartość, okrągłość, nieregularność) są jawnie obliczone. Ich skuteczność zależy przede wszystkim od precyzji segmentacji obrazu.
- Modele uczenia głębokiego wykazują wyższą efektywność, ponieważ mogą dokonywać jednoczesnej segmentacji i klasyfikacji kształtu. Architektury konwolucyjne są w stanie tworzyć wewnętrzne reprezentacje kształtu, co często przewyższa manualnie wybierane cechy kształtu w modelach klasycznych.
- Maksymalna wydajność klasyfikatorów jest więc osiągana dla modeli uczenia głębokiego. Tradycyjne modele uczenia maszynowego, przy skutecznym zastosowaniu ekstrakcji cech z obrazu, są w stanie osiągać porównywalnie dobre wyniki.

Metody analizy wyników z klasyfikatorów

Macierz pomyłek (Confusion Matrix)

Metryka	**Wzór**	**Interpretacja**	**Kiedy używać?**
Accuracy (Dokładność)	$\frac{TP+TN}{Wszystkie}$	Jaki % wszystkich decyzji był trafny.	Tylko przy zbalansowanych klasach. Bezużyteczna przy wykrywaniu rzadkich zdarzeń.
Precision (Precyzja)	$\frac{TP}{TP+FP}$	Jaka jest pewność, że X zostało prawidłowo zakwalifikowane.	Gdy koszt fałszywego alarmu (FP) jest wysoki.
Recall (Czułość / Sensitivity)	$\frac{TP}{TP+FN}$	Ile rzeczywistych X udało się wykryć?	Gdy koszt przeoczenia (FN) jest krytyczny.
F1-Score	$2 \cdot \frac{P \cdot R}{P+R}$	Średnia harmoniczna Precyzji i Czułości.	Kiedy ważny jest balans między precyzją a czułością.

Ocena progowania

ROC (Receiver Operating Characteristic) - wykres pokazujący relację między True Positive Rate (Recall) a False Positive Rate dla różnych progów odcięcia (np. czy klasyfikujemy jako "1" powyżej 0.5, czy powyżej 0.8 pewności).
AUC (Area Under Curve) - to pole pod krzywą ROC, dla AUC=0.5: model zgaduje losowo, dla AUC=1.0: model idealny

Regresja

Metryka	**Wzór**	**Interpretacja**	**Właściwości**
MSE (Mean Squared Error)	$\frac{1}{n}\sum(y-\hat{y})^2$	Średni błąd podniesiony do kwadratu.	Bardzo mocno karze duże pomyłki .
RMSE (Root MSE)	$\sqrt{MSE}$	Pierwiastek z MSE.	Wynik jest w tej samej jednostce co dane - nie są podniesione do kwadratu, co ułatwia interpretację.
MAE (Mean Absolute Error)	$\frac{1}{n}\sum$	$y-\hat{y}$	
R^2 (Współczynnik determinacji)	$1-\frac{SS_{res}}{SS_{tot}}$	Mówi, jaki procent zmienności danych "wyjaśnia" model.	$R^2=1$ - idealnie, $R^2=0$ - model przewiduje średnią,

Moje rekomendacje co do modeli klasycznych

- Logistic Regression jako pierwszy model i punkt odniesienia przy porównywaniu innych, potencjalnie skuteczniejszych modeli.
- Najpewniejszy i najbardziej zrównoważony klasyfikator – Random Forest, potencjalnie najlepszy klasyczny model, w przypadku gdy hiperparametryzacja SVM zawiedzie.
- Najskuteczniejszy klasyczny model przy wykrywaniu wystąpień nowotworu – SVM, niezbędna hiperparametryzacja w celu znalezienia złotego środka pomiędzy zwiększeniem występowania Fałszywych Negatywów a skutecznością wykrywania Fałszywych Pozytywów.
- Ze względu na trudność wdrożenia, potencjalna próba implementacji technik uczenia głębokiego powinna nastąpić tylko w przypadku, gdy klasyczne modele klasyfikacji będą już gotowe.

Konwolucyjne sieci neuronowe - alternatywa w stosunku do klasycznych metod klasyfikacji

- Mimo bardzo dobrych wyników tradycyjnych modeli, konwolucyjne sieci neuronowe (CNN) oparte o Deep Learning osiągają najwyższą trafność, osiągając nawet 99% skuteczności w kwalifikacji złośliwych zmian.
- CNN są w stanie przewyższyć modele klasyczne, ponieważ automatycznie wyodrębniają najważniejsze cechy (teksturalne, gradientowe i geometryczne) bezpośrednio z pikseli, co jest procesem bardziej wydajnym i mniej podatnym na błędy niż ekstrakcja cech z zastosowaniem radiomiki.
- Ze względu na trudność implementacji i stosunkowo wysoką skuteczność tradycyjnych modeli zalecam skupienie się przede wszystkim na testowaniu i implementacji klasycznych modeli Machine Learningowych.

Opisy badań naukowych dot. wykorzystania modeli Deep Learningowych w klasyfikacji mammogramów:

1. Deep learning in mammography images segmentation and classification: Automated CNN approach

   https://www.sciencedirect.com/science/article/pii/S1110016821002027

   Cel artykułu

   Autorzy chcieli stworzyć zautomatyzowany system komputerowy, który umożliwi lekarzom szybsze i dokładniejsze wykrywanie raka piersi na podstawie zdjęć rentgenowskich. Główne zadania stworzonego systemu to segmentacja - automatyczne wycięcie interesującego obszaru piersi ze zdjęcia, usuwając tło oraz szumy, np, etykiety i artefakty, oraz klasyfikacja, czyli ocena, czy wykryta zmiana jest łagodna czy złośliwa.

   Użyte dane

   Do treningu wykorzystano popularne, publicznie dostępne bazy danych medycznych:
   - MIAS (Mammographic Image Analysis Society) - 322 obrazów
   - DDSM (Digital Database for Screening Mammography) - 564 obrazów
   - CBIS-DDSM (Curated Breast Imaging Subset of DDSM) - 330 obrazów

   Po zastosowaniu augmentacji danych zbiór obrazów został odpowiednio powiększony.

Databases	Samples of training	Samples of testing	Total samples	Number of images after the process of augmentation
DDSM	451	113	564	1804
MIAS	257	65	322	1028
CBIS-DDSM	NA	330	330	NA

   Autorzy zastosowali segmentację przy użyciu modelu U-NET w celu znalezienia ROI (Region Of Interest). Następnie zastosowali maskowanie oryginalnych mammogramów na obrazy ROI.
   Ze względu na niewystarczającą ilość danych zastosowano techniki augmentacji danych (Data Augmentation) - czyli sztuczne powiększenie zbioru treningowego poprzez obracanie, przesuwanie i odbijanie istniejących zdjęć.

Użyte modele

Segmentacja opiera się o zmodyfikowany model sieci U-Net, który świetnie radzi sobie precyzyjnym zaznaczaniem kształtu.
Klasyfikacja opiera się na pięciu gotowych modelach konwolucyjnych sieci neuronowych (CNN), przy wykorzystaniu techniki Transfer Learningu, czyli douczania modeli, które już wcześniej widziały miliony innych obrazów. Autorzy podkreślają, że trening modelu od podstaw byłby kosztowny czasowo i obliczeniowo. Co więcej model mógłby być podatny na przeuczenie (overfitting).
Wykorzystane modele CNN:

- InceptionV3
- DenseNet121
- ResNet50
- VGG16
- MobileNetV2

Wyniki

Stworzony system osiągnął bardzo wysoką skuteczność. Najlepszym połączeniem okazał się U-Net oraz model IncepctionV3. Na zbiorze DDMS osiągnął on 98.87% dokładności (accuracy) oraz 98.88% AUC (Area Under Curve) - co oznacza, że model bardzo dobrze rozróżnia przypadki chore od zdrowych. Wynik czułości (sensitivity) model osiągnął na poziomie 98.98% co oznacza, że bardzo dobrze klasyfikuje prawdziwie pozytywnie (TP) przypadki. Inne metryki: 98.79% precyzji oraz 97.99% F1 score.

Wnioski

Ciekawym pomysłem jest skorzystanie z gotowych modeli sieci konwolucyjnych oraz douczenie ich na naszym zbiorze danych. Dzięki wykorzystaniu głębokich sieci do ekstrakcji cech z obrazu możemy uzyskać bardziej szczegółowe dane o obrazie oraz jego niewidocznych na pierwszy rzut oka cechach.

2. Breast Cancer Detection in Mammography Images: A CNN-Based Approach with Feature Selection

https://www.mdpi.com/2078-2489/14/7/410

Cel artykułu

Autorzy chcieli stworzyć nowy, skuteczniejszy system do automatycznej diagnozy raka piersi, który łączy zalety kilku różnych sieci neuronowych. Zamiast polegać na jednym modelu, autorzy postanowili połączyć funkcje kilku wstępnie wytrenowanych sieci, aby

uzyskać dokładniejszy opis obrazu i zminimalizować ryzyko pomyłki. Uzyskane cechy zostały zostały wykorzystane do uczenia zarówno sieci neuronowej jak i klasycznych modeli uczenia maszynowego: K-Nearest Neighbour, Random Forest oraz Support Vector Machine.

Użyte dane

Testy przeprowadzono na trzech znanych bazach obrazów mammograficznych:

1. RSNA (Radiological Society of North America) - 54713 obrazów od około 11 000 pacjentek - wszystkie zdjęcia pojedynczej pacjentki wykonane zostały z innych perspektyw.
2. MIAS (Mammographic Image Analysis Society) - opisane w poprzednim artykule
3. DDSM (Digital Database for Screening Mammography) - 55 890 obrazów, w tym 14% obrazów przedstawiających złośliwe przypadki.

Ze względu na niezbalansowanie zbioru danych (tylko 2% przypadków złośliwych) - użyte zostały wszystkie obrazy przedstawiające złośliwe przypadki oraz 2320 przypadków negatywnych.
Autorzy zauważyli, że zbiory te różnią się jakością i typem obrazów (np. RSNA jest trudniejszy do generalizacji przy użyciu modeli trenowanych na MIAS), co jest typowym problemem w inżynierii danych medycznych.

Użyte modele

Zastosowano podejście hybrydowe. Ekstrakcja cech oparta została o wstępnie wytrenowane sieci CNN. Modele te jedynie przetwarzały obraz na wektory cech.
Wykorzystano tutaj:

- EfficientNet - najlepszy pojedynczy model
- AlexNet
- MobileNetSmall
- ConvNeXt
- ResNet50

Wyekstrahowane cechy zostały połączone i poddane selekcji, a następnie przekazane do klasyfikatorów. Modele użyte do klasyfikacji:

- Sieć neuronowa (NN) - prosta sieć neuronowa okazała się najlepsza
- SVM
- KNN
- RF

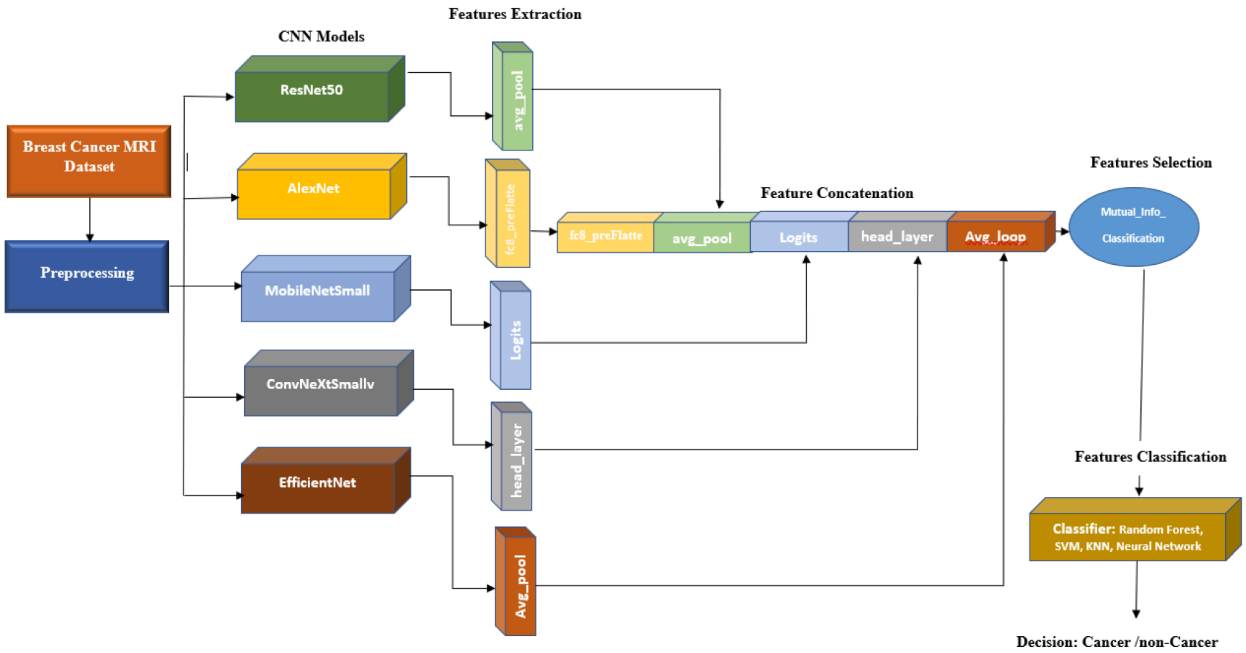

Normalizacja opierała się na skalowaniu wartości pixeli do wartości 0 - 255 w zbiorze danych RSNA. ROI został znaleziony poprzez wyodrębnienie konturu największego obiektu na obrazie, który odpowiada rozmiarowi piersi. Następnie wygenerowana została maska, która umożliwiła kadrowanie obrazu i wyizolowanie konkretnego obszaru zainteresowania.

Wyniki

Połączenie wyekstrahowanych przez CNN wektorów cech wraz z siecią neuronową (NN) dało najlepsze rezultaty.
Dokładność (Accuracy):

- 96% dla zbioru DDSM
- 94.5% dla zbioru MIAS
- 92% dla zbioru RSNA

Poniżej wyniki poszczególnych modeli:

Table 4. Performance comparison of the proposed method for different CNN models and Concat. Model with the NN classifier for RSNA dataset.

CNN Models	Acc	Sn	Pr	AUC	F-Score
AlexNet	81%	84%	87%	0.82	0.86
Resnet50	84%	90%	86%	0.89	0.88
MobileNetSmall	77%	85%	81%	0.81	0.83
ConvNexSmall	79%	87%	83%	0.83	0.85
EfficientNet	86%	92%	88%	0.92	0.90
Concat. Model	**92%**	**96%**	**92%**	**0.96**	**0.94**

Table 5. Performance comparison of the proposed method for different CNN models and Concat. Model with the kNN classifier for RSNA dataset.

CNN Models	Acc	Sn	Pr	AUC	F-Score
AlexNet	73%	70%	72%	0.70	0.71
Resnet50	72%	75%	71%	0.73	0.73
MobileNetSmall	64%	71%	67%	0.68	0.69
ConvNexSmall	66%	74%	70%	0.71	0.72
EfficientNet	71%	78%	74%	0.76	0.76
Concat. Model	**78%**	**81%**	**79%**	**0.82**	**0.80**

Table 6. Performance comparison of the proposed method for different CNN models and Concat. Model with the RF classifier for RSNA dataset.

CNN Models	Acc	Sn	Pr	AUC	F-Score
AlexNet	71%	67%	69%	0.68	0.68
Resnet50	69%	70%	67%	0.71	0.68
MobileNetSmall	60%	67%	63%	0.64	0.65
ConvNexSmall	62%	69%	65%	0.67	0.67
EfficientNet	73%	74%	70%	0.75	0.72
Concat. Model	**78%**	**79%**	**77%**	**0.80**	**0.78**

Table 7. Performance comparison of the proposed method for different CNN models and Concat. Model with the SVM classifier for RSNA dataset.

CNN Models	Acc	Sn	Pr	AUC	F-Score
AlexNet	62%	61%	63%	0.62	0.62
Resnet50	64%	66%	63%	0.65	0.64
MobileNetSmall	60%	63%	59%	0.60	0.61
ConvNexSmall	62%	65%	61%	0.63	0.63
EfficientNet	68%	70%	66%	0.68	0.68
Concat. Model	**73%**	**75%**	**72%**	**0.74**	**0.73**

Samo połączenie cech (Concatenation) podniosło skuteczność o ok. 6% w porównaniu do najlepszego pojedynczego modelu (EfficientNet). Model oparty o sieć neuronową zdominował klasyczne modele. Użycie klasycznych metod spowodowało spadek dokładności od kilku do kilkunastu procent.

Wnioski

Łączenie wektorów cech uzyskanych z kilku modeli nie jest głupim pomysłem - może poprawić dokładność modelu, ponieważ różne architektury interpretują obraz trochę inaczej. Podobnie jak w poprzedniej pracy, autorzy nie trenowali od zera, użyte zostały gotowe modele, co jest standardową i wydajną procedurą.
Dobór klasyfikatorów ma kluczowe znaczenie dla danego wektora cech, sieć neuronowa lepiej radzi sobie z nieliniowymi i złożonymi relacjami w danych wysokowymiarowych w porównaniu z wykorzystanymi klasycznymi klasyfikatorami.
Warto zwrócić uwagę na ilość obrazów o danej etykiecie, aby pracować na zbalansowanym zbiorze danych. W przypadku tego artykułu wykorzystanie niezbalansowanego zbioru danych przyniosłoby diametralnie słabsze wyniki.

3. Feature fusion and Ensemble learning-based CNN model for mammographic image classification

https://www.sciencedirect.com/science/article/pii/S1319157822001070

Cel artykułu

Autorzy chcieli stworzyć system do wykrywania raka piersi, który będzie bardziej niezawodny niż pojedynczy program. Badaczom zależało na redukcji przekłamania w diagnozach dla obrazów zaszumionych i niskiej jakości poprzez rozwiązanie problemu utraty informacji w głębokich warstwach sieci neuronowej oraz redukcję wariancji modelu.

Użyte dane

Do preprocessingu danych użyto techniki unsharp masking, która poprawia ostrość krawędzi obiektu. Do ekstrakcji ROI użyto zaś algorytmu Canny edge detection.Obrazy zostały przeskalowane do jednolitego wymiaru wejściowego wymaganego przez sieć CNN.
Zdjęcia użyte do treningu modelu pozyskano z bazy danych MIAS (322 obrazów, w tym 208 zdjęć przypadków łagodnych oraz 114 złośliwych). Do powiększenia danych użyto technikę augmentacji danych (obrót obrazu horyzontalnie, wertykalnie, obrót, zmiana skali, korekcja gamma). W ten sposób powiększono zbiór testowy do 4500 obrazów. Drugim zbiorem danych użytym do treningu modelu stał się BCRD (Breast Cancer Digital Repository). Do walidacji modelu zostało wykorzystanych 70 mammogramów, które zawierały 35 zdjęć przypadków złośliwego raka oraz 35 przypadków łagodnych. Kluczowymi dla autorów metrykami stały się czułość, swoistość oraz dokładność (sensitivity, specificity, accuracy).

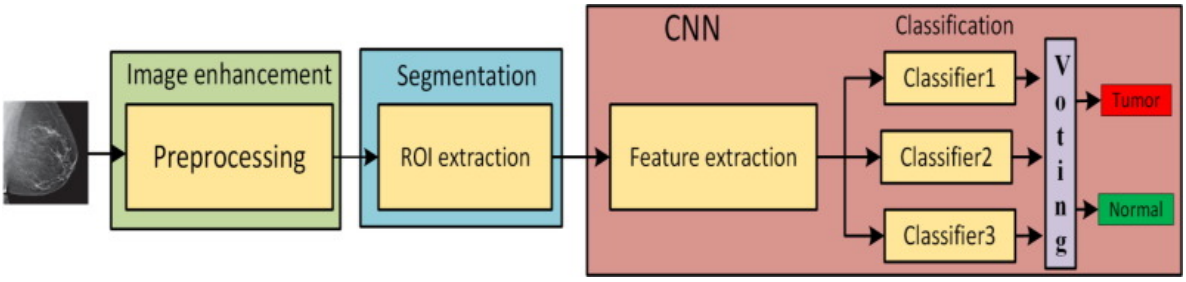

Użyte modele

W przeciwieństwie do innych artykułów, autorzy stworzyli własną architekturę CNN opartą na technice Snapshot Ensemble (w różnych momentach nauki modelu robimy “migawkę” - snapshot - wiedzy modelu, na koniec nauki modelu pojedyncze migawki są traktowane jak osobne modele, które głosują większościowo nad klasyfikacją danego zdjęcia. Technika ta usprawnia proces trenowania wielu sieci głębokich tylko po to, aby wyciągnąć średnią z ich predykcji. Dzięki łączeniu map cech wczesnych modeli, które są bogate w detale geometryczne, z mapami cech z warstw głębokich, rozwiązano problem zanikania informacji o detalach w głębokich warstwach. Jako punkt odniesienia do testów zostały użyte zarówno klasyczne algorytmy (SVM, KNN), jak i modele CNN (ResNet, VGG, AlexNet)

Wyniki

Model osiągnął skuteczność na poziomie 99.8%
Ilościowe wyniki modelu:

- Accuracy: 99.8%
- Precision: 99.4%
- Recall (Sensitivity): 99.3%
- F1-Score: 99.3%

Model	**Accuracy (Dokładność)**	**Precision (Precyzja)**	**Recall (Czułość)**	**F1-Score**
Snapshot Ensemble DCNN	99.83%	99.42%	99.30%	99.35%
ResNet-50	97.20%	96.50%	96.10%	96.30%
VGG-19	96.40%	95.80%	95.20%	95.50%
AlexNet	94.80%	93.90%	93.50%	93.70%
SVM (Tradycyjny ML)	91.50%	89.20%	88.50%	88.80%
KNN (Tradycyjny ML)	87.00%	85.50%	84.00%	84.70%

Wnioski

Trenowanie od zera własnych modeli deep learningowych jest zadaniem czasochłonnym. Ciekawą techniką, która może rozwiązać ten problem jest technik Snapshot Ensemble, dzięki której możemy uzyskać wiele modeli przydatnych, gdy implementujemy mechanizm głosowania przy klasyfikacji zdjęcia. Użycie tej techniki zmniejsza także prawdopodobieństwo utraty informacji o drobnych detalach przy uczeniu głębokim. Przedstawiono także sposób na radzenie sobie z małą ilością danych - augmentacja danych.

4. Convolutional neural networks for mammography mass lesion classification

https://ieeexplore.ieee.org/abstract/document/7318482

Cel artykułu

Celem artykułu jest zastąpienie klasycznego podejścia opartego na ręcznej ekstrakcji cech automatycznym uczeniem reprezentacji cech za pomocą CNN do klasyfikacji zmian w mammografii.

Użyte dane

Podobnie jak w innych badaniach użyty został zbiór BCDR. Składał się z on 736 obrazów zawierającymi 426 łagodnych i 310 złośliwych zmian oraz dane kliniczne i deskryptory oparte na obrazach. Autorzy analogicznie do innych badaczy zastosowali augmentację danych w celu zwiększenia zbioru treningowego. Preprocessing obejmował normalizację obrazów poprzez wyostrzenie konturów krawędzi, zmianę jasności i kontrastu oraz ekstrakcję wycinków obrazów o stałym rozmiarze 150x150 pikseli. Dane podzielono w proporcji 60/40 w taki sposób, aby obrazy należące do tego samego pacjenta nie pojawiły się zarówno w zbiorze testowym jak i treningowym, aby nie zaburzyć treningu modelu

Użyte modele

Autorzy nie wykorzystali gotowego modelu. Stworzyli swoją własną, prostą sieć sekwencyjną. Do zestawienia autorskiego modelu użyto klasycznego modelu SVM.
Eksplorację parametrów sieci CNN przeprowadzono poprzez wyodrębnienie jednej szóstej zbioru treningowego jako zbioru walidacyjnego, wytrenowanie 25 modeli z losową inicjalizacją hiperparametrów i wybranie najlepszego modelu na podstawie wydajności walidacji. Zbiór treningowy został wykorzystany do dostrojenia parametrów dla klasyfikatora SVM poprzez wykonanie 20 przebiegów.

Ze względu na skomplikowany mechanizm działania modeli sieci głębokich, poniżej zamieszczam uproszczony schemat działania powyższego modelu:

- Wejście: Sieć przyjmuje mały obrazek o wymiarach 150×150 pikseli.
- Wyciąganie cech (Filtrowanie): Zamiast patrzeć na piksele pojedynczo, sieć przesuwa po obrazie małe okienka (filtry). Szuka w nich krawędzi, kształtów czy tekstur charakterystycznych dla guzów.
- Zmniejszanie (Pooling): Żeby nie przetwarzać gigantycznej ilości danych, sieć co chwilę "streszcza" obraz, wybierając tylko najważniejsze informacje (np. najsilniejszy sygnał z danego obszaru) i odrzucając szum.

- Decyzja (Klasyfikacja): Na końcu "spłaszczone" informacje trafiają do klasycznego klasyfikatora, który na podstawie zebranych cech wyrzuca wynik: klasa 1 lub klasa 2.

Autorzy podkreślają, że sieć ma dużo parametrów (4.6 miliona), więc musieli użyć trików (regularyzacji), żeby nie doszło do przeuczenia sieci. Wykorzystano dropout, czyli losowe wyłączanie neuronów w trakcie nauki oraz ograniczenie normy wektora wag wchodzących do neuronu.

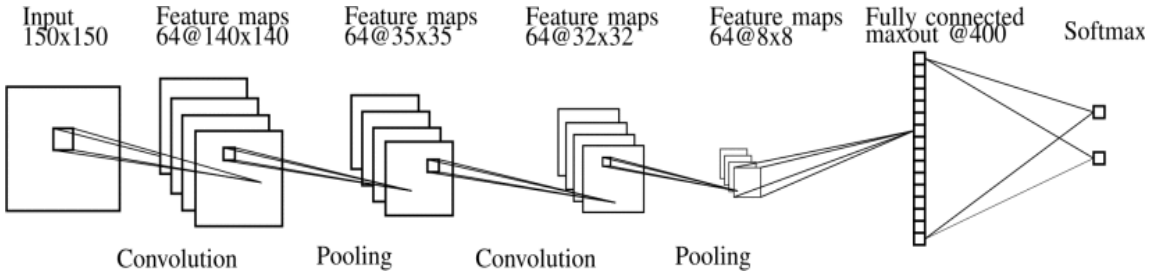

Wyniki

Model CNN osiągnął wynik 86% AUC, co w 2015 roku było znaczącym osiągnięciem. Autorzy porównali swoje podejście SVM, która była karmiona ręcznie wyliczonymi cechami (np. deskryptory tekstury, kształtu). CNN przewyższyło SVM pod względem dokładności i zdolności generalizacji, eliminując potrzebę projektowania cech dla klasycznych modeli (feature engineering).

Wnioski

Już w 2015 roku znaczącą przewagę nad tradycyjnymi modelami uczenia maszynowego uzyskiwały modele uczenia głębokiego. Wykorzystanie konwolucyjnych sieci neuronowych zdecydowanie upraszcza proces ekstrakcji cech z obrazu, ponieważ model sam odnajduje zależności, przez co samodzielny proces tworzenia wektora cech dla modelu jest w znacznym stopniu uproszczony.

Wykorzystanie modeli Deep Learningowych w literaturze - porównanie z klasycznymi modelami

Wyniki badań oraz autorzy powyższych artykułów pokazują przewagę modeli głębokiego uczenia nad modelami klasycznymi. W modelach klasycznych niezbędne jest ręczne projektowanie cech, co jest czasochłonne, a sam proces z natury narażony jest na niedopatrzenia i ludzkie błędy. Sieć neuronowa sama uczy się cech bezpośrednio z obrazów. Dzięki temu może ona zauważyć niewidoczne ludzkim okiem różnice w zbiorze danych oraz wzorce, które nie da się łatwo opisać równaniami matematycznymi. Modele CNN widzą korelacje nieliniowe w tysiącach wymiarów, jest to statystyka na ogromną skalę, której ludzki mózg nie przetworzy - co daje ogromną przewagę w procesie klasyfikacji obrazów. Klasyczne podejścia często zakładają pewną strukturę danych, np. liniową separowalność. Rzeczywiste dane, w tym przypadku obrazy, leżą na skomplikowanych rozmaitościach (manifolds) w przestrzeni wielowymiarowej, co daje im ogromną przewagę.

Skuteczność klasyfikatorów na cechach kształtu - porównanie z podejściem Deep Learningowym

Klasyczne modele bazują na konturach i binarnych maskach. Są także wrażliwe na szum i zakłócenia w danych treningowych, przez co niezbędny jest precyzyjny preprocessing. Co więcej, zmiana oświetlenia lub częściowe zasłonięcie badanego obiektu może zniweczyć próbę klasyfikacji. Sieci CNN kodują informacje nie tylko o geometrii, ale także o kontekście przestrzennym i teksturze na obrazie. Jeżeli kształt jest w jakiś sposób zniekształcony, sieć wykorzystuje nadmiarowe informacje z innych kanałów, aby dokonać poprawnej predykcji. W naszym zbiorze treningowych nie ma problemu z szumem w danych testowych, ponieważ w zasadzie preprocessing został przeprowadzony za nas. Mimo to modele sieci głębokich nadal mają przewagę w problemie klasyfikacji obrazu. Są w stanie dostrzec niewidoczne na pierwszy rzut oka zależności, które ciężko opisać funkcją matematyczną. Co więcej, zastosowanie modeli sieci głębokich upraszcza proces definiowania wektorów cech kształtu, które w klasycznym podejściu musiałyby być zaprojektowane przez człowieka, co zwiększa ryzyko popełnienia błędu i zmniejszenia dokładności predykcji. Podejście Deep Learningowe w klasyfikacji na podstawie cech kształtu ma więc przewagę nad tradycyjnym podejściem z użyciem modeli uczenia maszynowego, lecz ze względu na skomplikowaną implementację modelu uczenia głębokiego zalecam przede wszystkim na skupieniu się na klasycznych metodach klasyfikacji.

Źródła

[1] Mammography classification using modified hybrid SVM-KNN: https://ieeexplore.ieee.org/abstract/document/8305858

[2] Performance analysis of support vector machines classifiers in breast cancer mammography recognition: https://link.springer.com/article/10.1007/s00521-012-1324-4

[3] Classification of Mammograms Using Decision Trees: https://ieeexplore.ieee.org/abstract/document/4041628

[4] Performance analysis of mammogram CAD system using SVM and KNN classifier:

https://ieeexplore.ieee.org/abstract/document/8068653

[5] A Logistic Regression Model Based on the National Mammography Database Format to Aid Breast Cancer Diagnosis: https://ajronline.org/doi/full/10.2214/AJR.07.3345

[6] An investigate of mass diagnosis in mammogram with random forest https://ieeexplore.ieee.org/abstract/document/6160086

[7] Classification of Mammography Images by Machine Learning Techniques https://ieeexplore.ieee.org/abstract/document/8566380

[8] Discovering Mammography-based Machine Learning Classifiers for Breast Cancer Diagnosis https://link.springer.com/article/10.1007/s10916-011-9693-2

[9] Classification of Breast Cancer Tumors using a Random Forest on Mammogram Images: https://ami.info.umfcluj.ro/index.php/AMI/article/view/920/847

[10] Deep learning in mammography images segmentation and classification: Automated CNN approach: https://www.sciencedirect.com/science/article/pii/S1110016821002027

[11] Breast Cancer Detection in Mammography Images: A CNN-Based Approach with Feature Selection: https://www.mdpi.com/2078-2489/14/7/410

[12] Feature fusion and Ensemble learning-based CNN model for mammographic image classification: https://www.sciencedirect.com/science/article/pii/S1319157822001070

[13] Convolutional neural networks for mammography mass lesion classification: https://ieeexplore.ieee.org/abstract/document/7318482

Pozostałe źródła użyte w Notebook LM podane w linku do poszczególnych notatników

Analiza przy użyciu Notebook Deep Research

Link do analizy pierwszej części researchu:

https://notebooklm.google.com/notebook/1f4c8ecf-be6c-419c-b200-b87a136bad85

Link do analizy drugiej części researchu:

https://notebooklm.google.com/notebook/c2dac60f-769a-49bd-a6c9-674b085aa4be

Raporty dostępne także w oddzielnych plikach.