Klasyczne vs. Głębokie Uczenie: Nowe Horyzonty w Diagnostyce Raka Piersi

Porównawcza Analiza Architektury, Wydajności i Perspektyw w Predykcji Złośliwości

NotebookLM

Wyzwanie Kliniczne: Skala Problemu i Ograniczenia Diagmostyki Manualnej

Kluczowe Statystyki

- Rak piersi to najczęściej występujący nowotwór u kobiet: **2.1 miliona nowych przypadków** w 2018 r. (Źródło: IARC/WHO)
- Główna przyczyna zgonów nowotworowych u kobiet: **627 000 zgonów** w 2018 r. (Źródło: IARC/WHO)
- Wczesne wykrycie może zredukować śmiertelność **z 40% do 15%**. (Źródło: Winters et al.)

Continuum Zmian

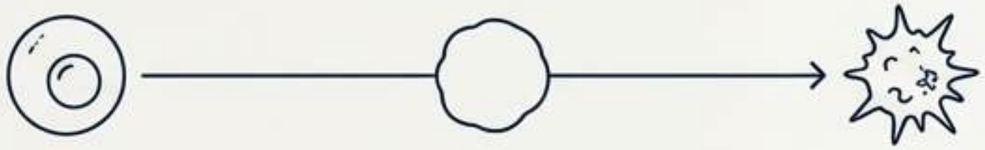

Zmiana łagodna

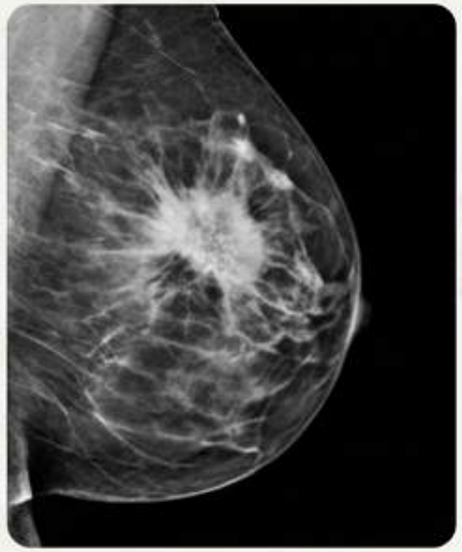

Zmiana złośliwa

Rola i Ograniczenia Systemów CAD

Cel CAD

Zwiększenie czułości, obiektywności i szybkości diagnozy.

Ograniczenia manualnej oceny

- Niedobór ekspertów ze specjalistyczną wiedzą.
- Ryzyko subiektywności i błędów ludzkich.
- Proces czasochłonny, ograniczający liczbę badanych przypadków.

NotebookLM

Nasz Fundament: Rola Precyzyjnej Segmentacji w Radiomice

Problem 'Wąskiego Gardła'

Segmentacja, czyli wyznaczenie konturu guza (ROI), jest kluczowym, lecz często problematycznym krokiem w radiomice.

- Ręczna segmentacja jest czasochłonna, subiektywna i stanowi główne źródło wariancji w modelach predykcyjnych. (Źródło: "Porównawcza Analiza...")

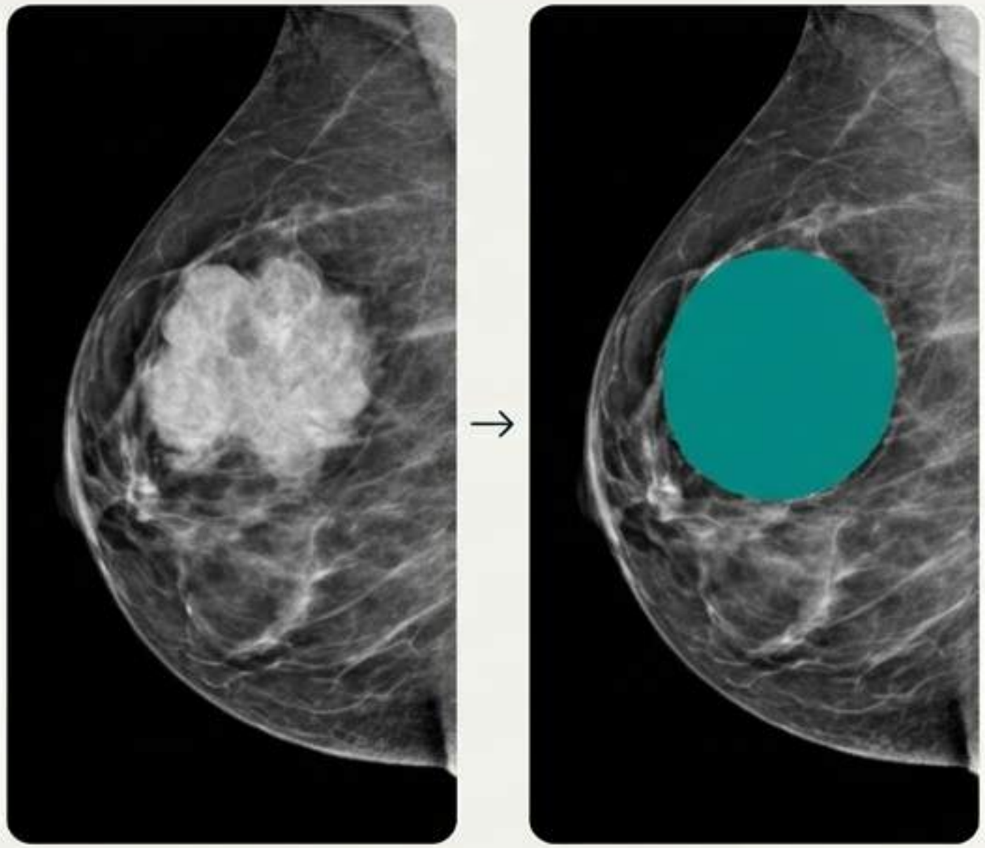

Od obrazu do precyzyjnej cechy geometrycznej

Kluczowy Atut Projektu

Dysponujemy zbiorem ponad **1400 obrazów** z precyzyjnymi, binarnymi maskami (0-1) konturów guza.

- Eliminuje to błędy segmentacji i maksymalizuje potencjał informacyjny cech radiomicznych, zwłaszcza tych opisujących kształt guza.
- Dzięki temu możemy ustanowić wysoce wiarygodny punkt odniesienia (benchmark) dla modeli CML.

NotebookLM

Paradygmat I (Teza): Klasyczne Uczenie Maszynowe i Inżynieria Cech 'Top-Down'

Definicja podejścia CML/Radiomiki

- Cechy są *a priori* definiowane przez ekspertów na podstawie wiedzy domenowej i klinicznej.
- Model opiera się na ekstrakcji precyzyjnych, **matematycznie zdefiniowanych atrybutów** obrazu, takich jak kształt, tekstura czy krawędzie.

Kluczowe Zalety

- **Transparentność i Interpretowalność**: Wynik predykcji można bezpośrednio powiązać z **konkretnymi, klinicznie zrozumiałymi atrybutami guza** (np. "model wskazał na złośliwość z powodu wysokiego indeksu spikulacji').
- **Mniejsze Zapotrzebowanie na Dane**: Modele CML mogą być bardziej **stabilne** przy **ograniczonych zbiorach danych** w porównaniu do modeli DL.

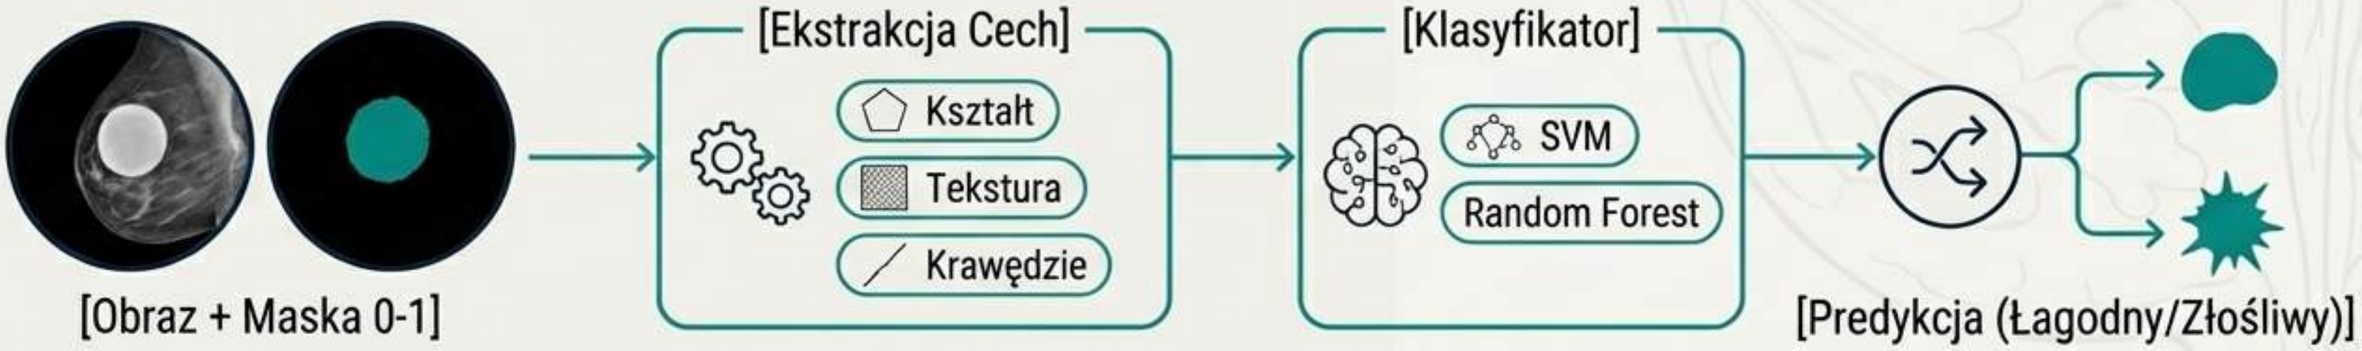

NotebookLM

Przekładając Cechy Kształtu na Kryteria Kliniczne (BI-RADS)

Cechy kształtu i marginesów są jednymi z najważniejszych predyktorów złośliwości, bezpośrednio skorelowanymi z leksykonem BI-RADS (Breast Imaging Reporting and Data System).

Spikulacja (Spiculated Margins)

Linie promieniujące od masy, wskazujące na inwazyjny wzrost. Najsilniejszy predyktor złośliwości.

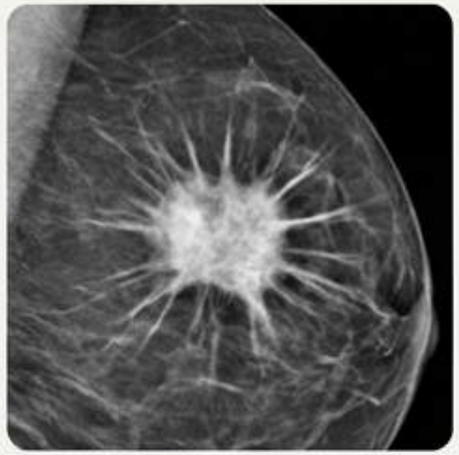

Metryka Radiomiczna: Indeks Spikulacji (SI)

Nieregularność Kształtu (Irregular Shape)

Odstępstwo od kształtu okrągłego/owalnego; często zrazikowy (lobular) lub gwiaździsty. Wskaźnik agresywnego wzrostu.

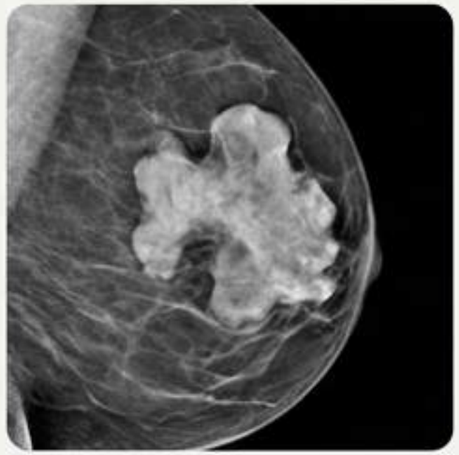

Metryka Radiomiczna: Wymiar Fraktalny (FD), Współczynnik Zwarcia (Compactness)

Niejednoznaczne Granice (Indistinct Margins)

Niewyraźne, zatarte granice guza, w przeciwieństwie do gładkich i dobrze odgraniczonych w zmianach łagodnych.

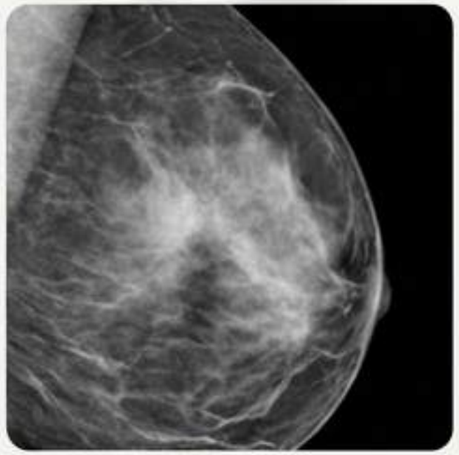

Metryka Radiomiczna: Miary ostrości krawędzi (Acutance, Contrast)

NotebookLM

Potencjalny Pułap Wydajności CML: Osiągnięcie Doskonałości?

Kluczowe Badanie

Badanie Mu et al. (2008) wykazało, że nieliniowe klasyfikatory (np. Kernel SVM) oparte na zoptymalizowanym zestawie cech radiomicznych (kształt, ostrość krawędzi, krawędzi, tekstura) osiągnęły wydajność

AUC = 0.95

Argument

Wynik ten, identyczny z zaawansowanymi modelami hybrydowymi, dowodzi, że przy precyzyjnych danych wejściowych, CML może w pełni uchwycić kluczowe informacje diagnostyczne.
W naszym projekcie, dzięki precyzyjnym w precyzyjnym maskom 0-1, paradygmat CML stanowi niezwykle silny i trudny do pokonania punkt odniesienia (benchmark).

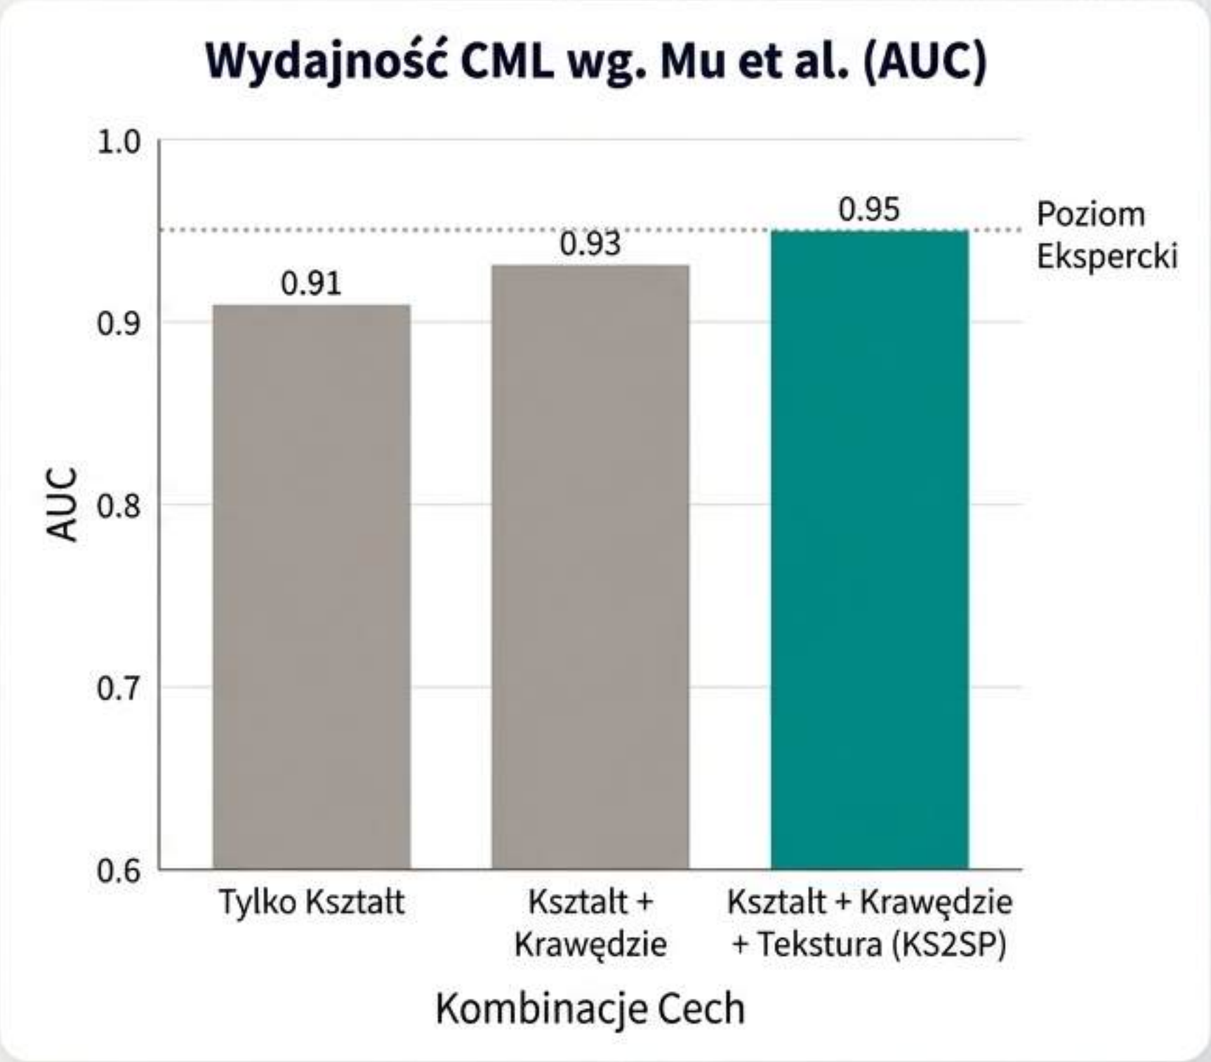

NotebookLM

Paradygmat II (Antyteza): Głębokie Uczenie i Automatyczna Ekstrakcja Cech 'Bottom-Up'

Definicja podejścia DL (CNN)
W przeciwieństwie do CML, modele DL (zwłaszcza CNN) nie wymagają ręcznej inżynierii cech.
Sieci uczą się reprezentacji danych automatycznie, w sposób hierarchiczny, bezpośrednio z surowych pikseli obrazu.

Kluczowe Zalety
Wychwytywanie Subtelnych Wzorców: Zdolność do identyfikacji złożonych, nieliniowych wzorców tekstury, niewidocznych dla ludzkiego oka i niedefiniowalnych w CML.
Skalowalność: Wydajność modelu rośnie wraz ze wzrostem ilości i różnorodności danych treningowych.

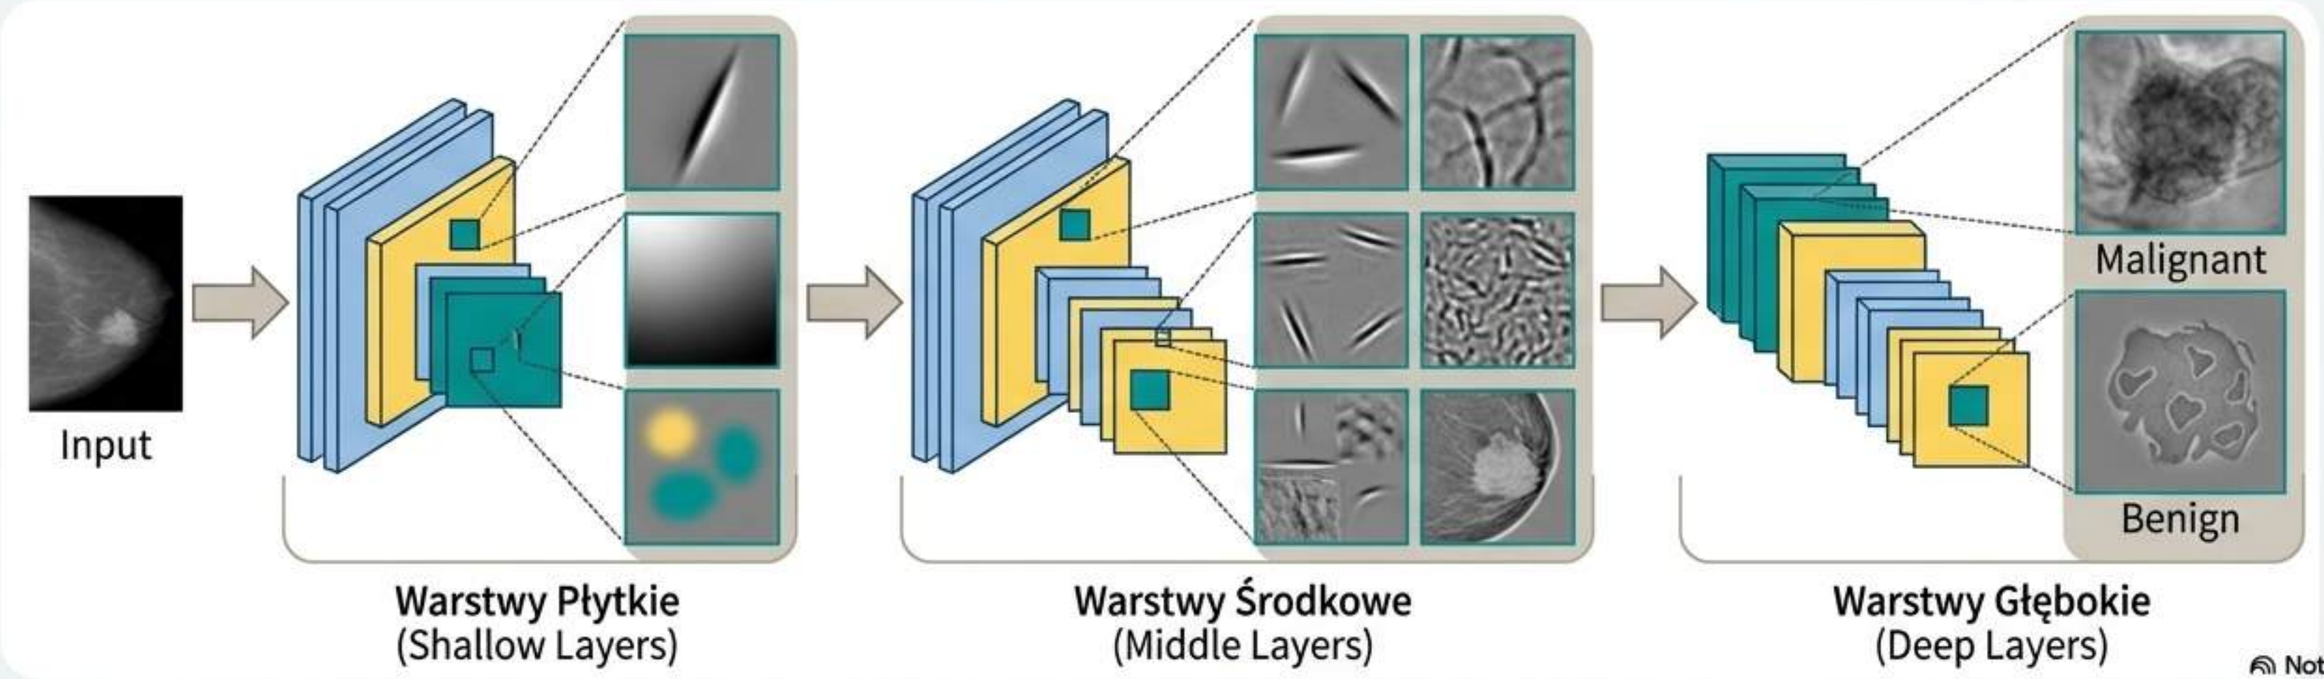

NotebookLM

Architektury i Rola Transfer Learning w Obrazowaniu Medycznym

Kluczowe Architektury i ich Wydajność

Standardem w obrazowaniu medycznym stały się zaawansowane architektury CNN, takie jak ResNet, DenseNet czy GoogLeNet (Inception).

Wyniki z badania porównawczego (Źródło: "Evaluating Deep Learning Models...")

Model	Dokładność
ResNet-50	92%
GoogLeNet (Inception v3)	**93%**
DenseNet-121	92%

Wyjaśnienie Transfer Learning

Problem: Modele DL są 'głodne danych' i wymagają ogromnych zbiorów do skutecznego treningu. Zbiory medyczne są często ograniczone.
Rozwiązanie: *Transfer Learning* – wykorzystanie modeli wstępnie wytrenowanych na ogromnych zbiorach danych (np. ImageNet). Sieć posiada już wiedzę o ogólnych cechach wizualnych (krawędzie, tekstury).

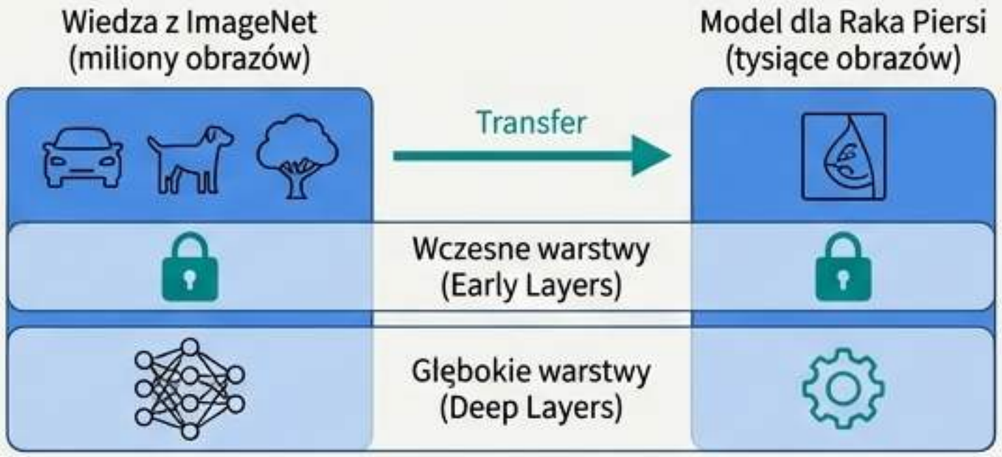

Proces: 'Zamrażamy' wczesne warstwy sieci i dostrajamy (fine-tuning) tylko głębsze, bardziej wyspecjalizowane warstwy na naszym zbiorze danych medycznych.

NotebookLM

Potęga i Paradoks: Przewaga w Atypowych Przypadkach vs. Problem ‘Czarnej Skrzynki’

Główna Siła DL

DL doskonale radzi sobie z przypadkami, gdzie cechy kształtu są mylące. Jest w stanie zidentyfikować złośliwość na podstawie subtelnych wzorców tekstury wewnątrz guza.

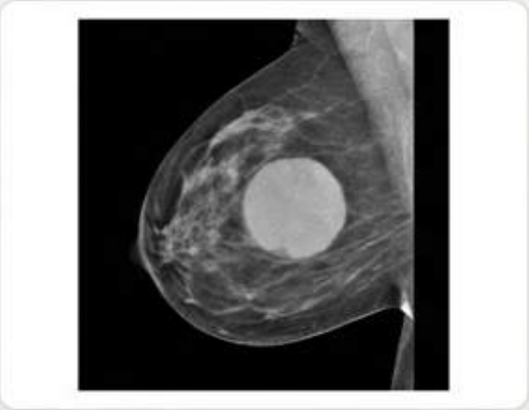

Dla CML – trudny przypadek

[Fractal Analysis of Contours, of anekro ar soonam malignant tumormerme (CM), Wiv. 18, 0226021293-2024]

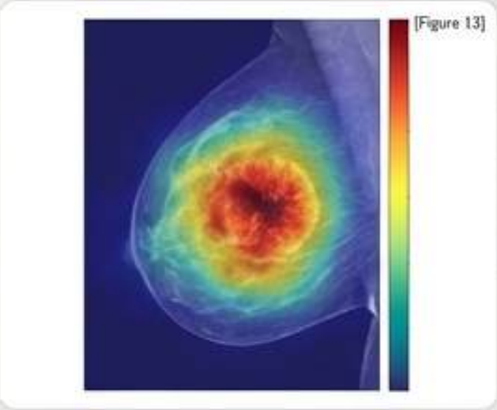

Dla DL – kluczowe wzorce tekstury

[Figure 13]

DL widzi więcej, ale czy możemy mu zaufać, nie wiedząc, na co patrzy?

Główna Wada DL – “Czarna Skrzynka”

Mimo wysokiej dokladności, proces decyzyjny modelu DL jest nieprzejrzysty. Trudno jest zrozumieć, *dlaczego* sieć podjęła daną decyzję.

Ten brak interpretowalności jest główną barierą dla zaufania klinicznego i adopcji technologii w praktyce medycznej.

NotebookLM

Synteza: Fuzja Cech Głębokich i Radiomicznych dla Maksymalnej Wydajności

Logika Modelu Hybrydowego

Podejście hybrydowe łączy komplementarne informacje z obu paradygmatów, dążąc do synergii i przełamania indywidualnych ograniczeń.

- **Strumień DL (CNN):** Analizuje cały obraz (lub ROI), automatycznie ucząc się złożonych, hierarchicznych cech **tekstury** i wzorców wewnętrznych.
- **Strumień CML (Radiomika):** Wykorzystuje precyzyjną maskę 0-1 do ekstrakcji robustnych, interpretowalnych cech **kształtu** i marginesów.

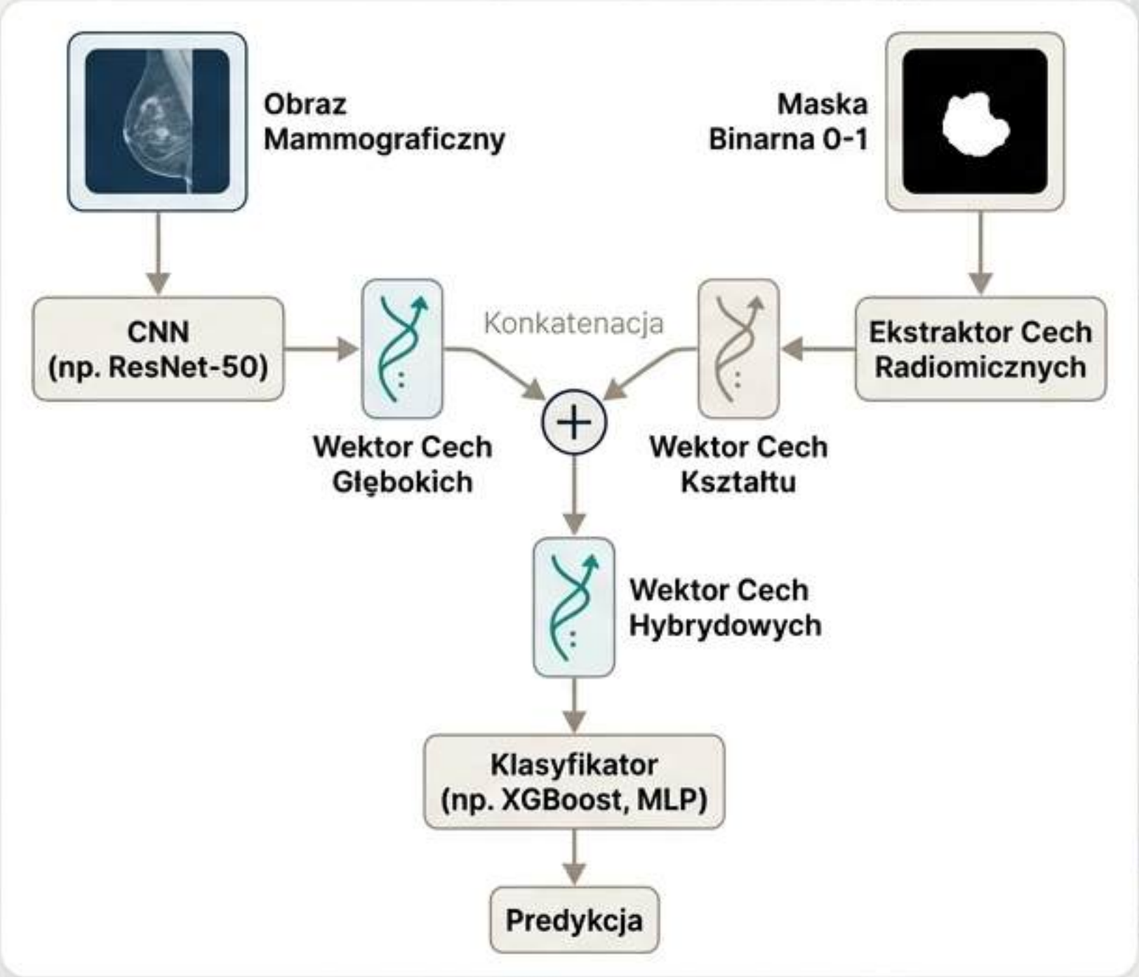

NotebookLM

Dowód Przewagi: Jak Fuzja Cech Przełamuje Bariery Wydajności

Argument "1 + 1 > 2": Fuzja cech prowadzi do synergii, gdzie połączony model osiąga lepsze wyniki niż suma jego części.

Kluczowe Wyniki z Badań:

- **Badanie 1 (CEM):** "W badaniu nad klasyfikacją zmian na mammogramach wzmocnionych kontrastem, model hybrydowy (DL + radiomika) osiągnął najwyższe **AUC = 0.95**, przewyższając zarówno model oparty wyłącznie na DL, jak i model CML." (Źródło: 'Combining Deep Learning and Handcrafted Radiomics...').
- **Badanie 2 (CBIS-DDSM):** "W badaniu Sajid et al., połączenie cech głębokich (z cVGG) z cechami ręcznymi (HOG, LBP) i klasyfikatorem XGBoost podniosło dokładność z **60%** (tylko DL) do **91.5%** (model hybrydowy).' (Źródło: 'Breast Cancer Classification using Deep Learned Features...').

Wzrost Dokładności dzięki Fuzji Cech (Sajid et al.)

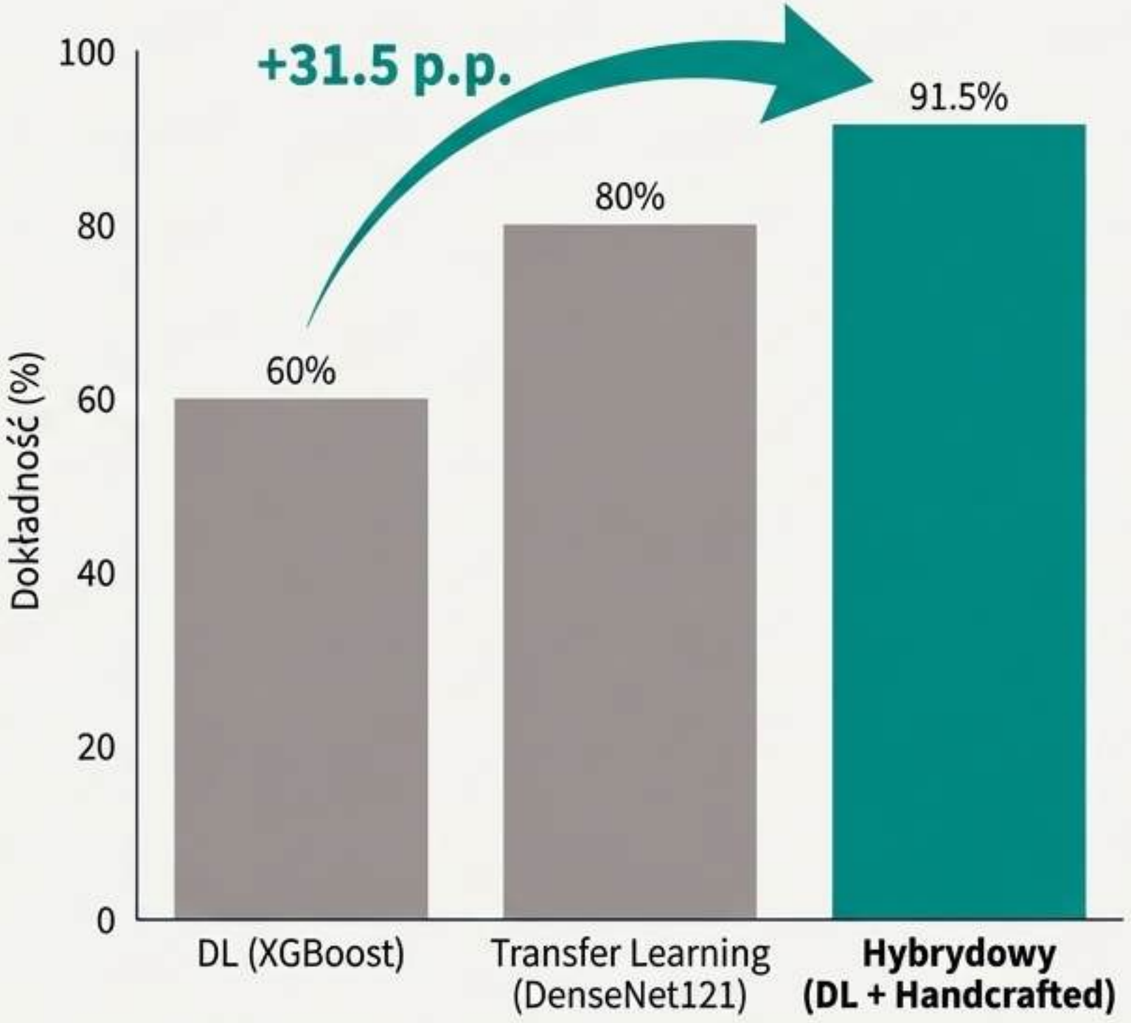

NotebookLM

Innowacje w Architekturach: Przypadek Zintegrowanych Modeli CNN-LSTM

Wprowadzenie

Poza prostą fuzją wektorów cech, zaawansowane modele **hybrydowe** integrują różne typy sieci neuronowych w jednej, spójnej architekturze.

Architektura CNN-LSTM

- **CNN**: Działa jako potężny ekstraktor cech przestrzennych, przekształcając obraz w sekwencję map cech.
- **LSTM (Long Short-Term Memory)**: Przetwarza sekwencję cech z CNN, modelując złożone zależności i kontekst między nimi – analogicznie do analizy sekwencji w danych czasowych lub tekście.

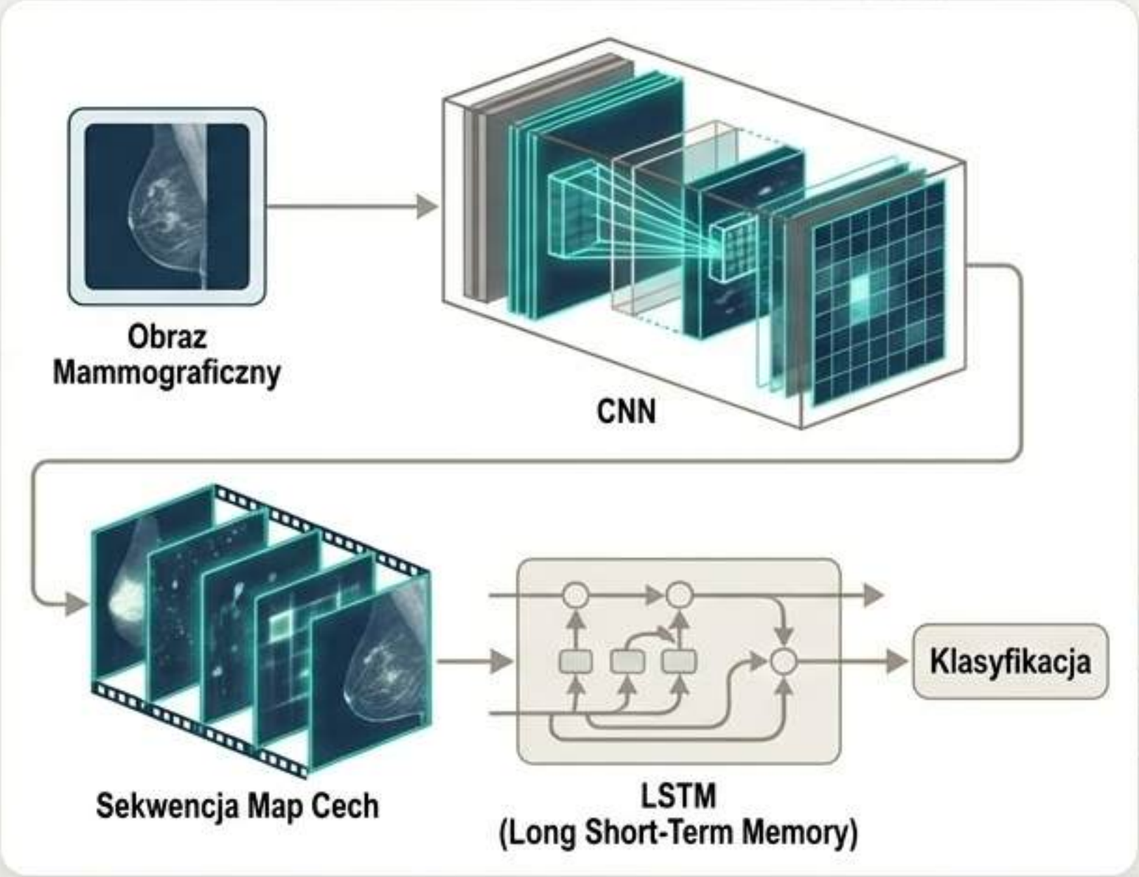

Wyniki Badań

Hybrydowy model CNN-LSTM zademonstrował wyjątkową skuteczność, osiągając dokładność **99.90%** na jednym ze zbiorów danych, co przewyższyło standardowe architektury jak ResNet-50 i VGG-16. (Źródło: 'Breast cancer classification based on hybrid CNN with LSTM model')

Wniosek: Pokazuje to potencjał innowacyjnych architektur w modelowaniu ukrytych, złożonych wzorców, które mogą umykać nawet standardowym CNN.

NotebookLM

Ku Wyjaśnialnej AI (XAI) i Medycynie Spersonalizowanej

Architektura hybrydowa stanowi idealny pomost między wydajnością a zaufaniem klinicznym.

Dwa Filary Wyjaśnialności

Interpretowalność Cech (z CML)

Wektor cech radiomicznych (kształt, spikulacja) dostarcza bezpośrednio interpretowalnych predyktorów. Możemy stwierdzić, że np. 30% wagi decyzji opierało się na wysokim indeksie spikulacji.

Wpływ Cech na Decyzję

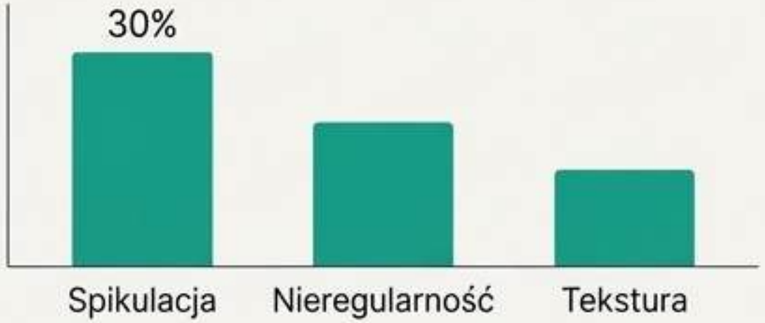

Wizualizacja Uwagi (z DL)

Mapy aktywacji, takie jak Grad-CAM, wizualizują obszary obrazu, na których sieć CNN skupiła swoją 'uwagę'. To pozwala zweryfikować, czy model patrzy na klinicznie istotne regiony, a nie na artefakty.

Wizja Przyszłości

Celem nie jest tylko 'lepsza predykcja', ale **“lepsza, godna zaufania i klinicznie użyteczna predykcja”**.

NotebookLM

Podsumowanie Porównawcze Trzech Paradygmatów

Aspekt	CML / Radiomika (Teza)	Głębokie Uczenie (Antyteza)	Model Hybrydowy (Synteza)
Ekstrakcja Cech	Ręczna, "Top-Down", oparta na wiedzy eksperckiej.	Automatyczna, "Bottom-Up", uczona hierarchicznie.	Połączenie obu: ręczna dla kształtu, automatyczna dla tekstury.
Interpretowalność	**Wysoka**. Bezpośrednie powiązanie z cechami klinicznymi.	**Niska** ("czarna skrzynka"). Trudność w wyjaśnieniu decyzji.	**Średnia do Wysokiej.** Łączy interpretowalne cechy CML z wizualizacją uwagi DL (XAI).
Wydajność	Wysoka w idealnych warunkach (AUC do 0.95), ale ograniczona przez definicję cech.	Bardzo wysoka, zwlaszcza w złożonych przypadkach. Skaluje się z danymi.	**Najwyższa**. Efekt synergii, przełamuje indywidualne sufity wydajności (AUC > 0.95).
Zapotrzebowanie na Dane	Umiarkowane. Stabilniejsza przy mniejszych zbiorach.	Duże. Wymaga Transfer Learning przy ograniczonych danych.	Umiarkowane do dużego. Korzysta z zalet obu podejść.
Optymalne Zastosowanie	Ustanowienie benchmarku, zadania wymagające pełnej transparentności.	Analiza złożonej tekstury, maksymalizacja automatyzacji na dużych zbiorach.	**Złożone zadania diagnostyczne wymagające maksymalnej dokładności i zaufania klinicznego.**

Model hybrydowy oferuje najlepszy kompromis, maksymalizując wydajność predykcyjną przy jednoczesnym zachowaniu kluczowych elementów interpretowalności, co czyni go optymalną strategią wdrożeniową.

NotebookLM

Rekomendacja Strategiczna i Następne Kroki

Wdrożenie **modelu hybrydowego**, który wykorzystuje **unikalny atut projektu (precyzyjne maski 0–1)** i **łączy go z mocą głębokiego uczenia**, jest najbardziej obiecującą i racjonalną ścieżką rozwoju.

Rekomendowany Trójetapowy Plan Wdrożenia

Etap 1: Foundation

Ustanowienie Benchmarku CML

Ekstrakcja zoptymalizowanego zestawu cech radiomicznych z masek 0-1.

Trening i walidacja klasyfikatorów CML (SVM, XGBoost) w celu ustalenia solidnej wydajności bazowej.

Etap 2: Performance Boost

Wdrożenie Modelu DL

Implementacja architektury CNN (np. ResNet-50) z wykorzystaniem Transfer Learning.

Dostrojenie modelu na zbiorze danych i ocena jego samodzielnej wydajności.

Etap 3: Synthesis & Validation

Budowa i Walidacja Modelu Hybrydowego

Fuzja wektorów cech z Etapu 1 i Etapu 2

Trening i rygorystyczna walidacja finalnego modelu hybrydowego w celu potwierdzenia przewagi nad modelami indywidualnymi.

NotebookLM