Sztuczna Inteligencja w Diagnostyce Raka Piersi: Od Danych do Precyzyjnej Diagnozy

Synteza zaawansowanych technik analitycznych: od radiomiki po hybrydowe modele głębokiego uczenia.

Tradycyjna interpretacja obrazów mammograficznych, choć jest złotym standardem, boryka się z wyzwaniami takimi jak wysoki odsetek wyników fałzywie dodatnich i ujemnych, co prowadzi do niepotrzebnych biopsji i opóźnień w diagnozie.

Sztuczna inteligencja (AI) oferuje przełom, przekształcając obrazy w kwantyfikowalne dane i odkrywając wzorce niewidoczne dla ludzkiego oka.

Ta prezentacja przedstawia ewolucję metod AI – od fundamentalnej radiomiki, przez klasyczne uczenie maszynowe, aż po najnowocześniejsze modele hybrydowe, które **rewolucjonizują dokładność diagnostyczną**.

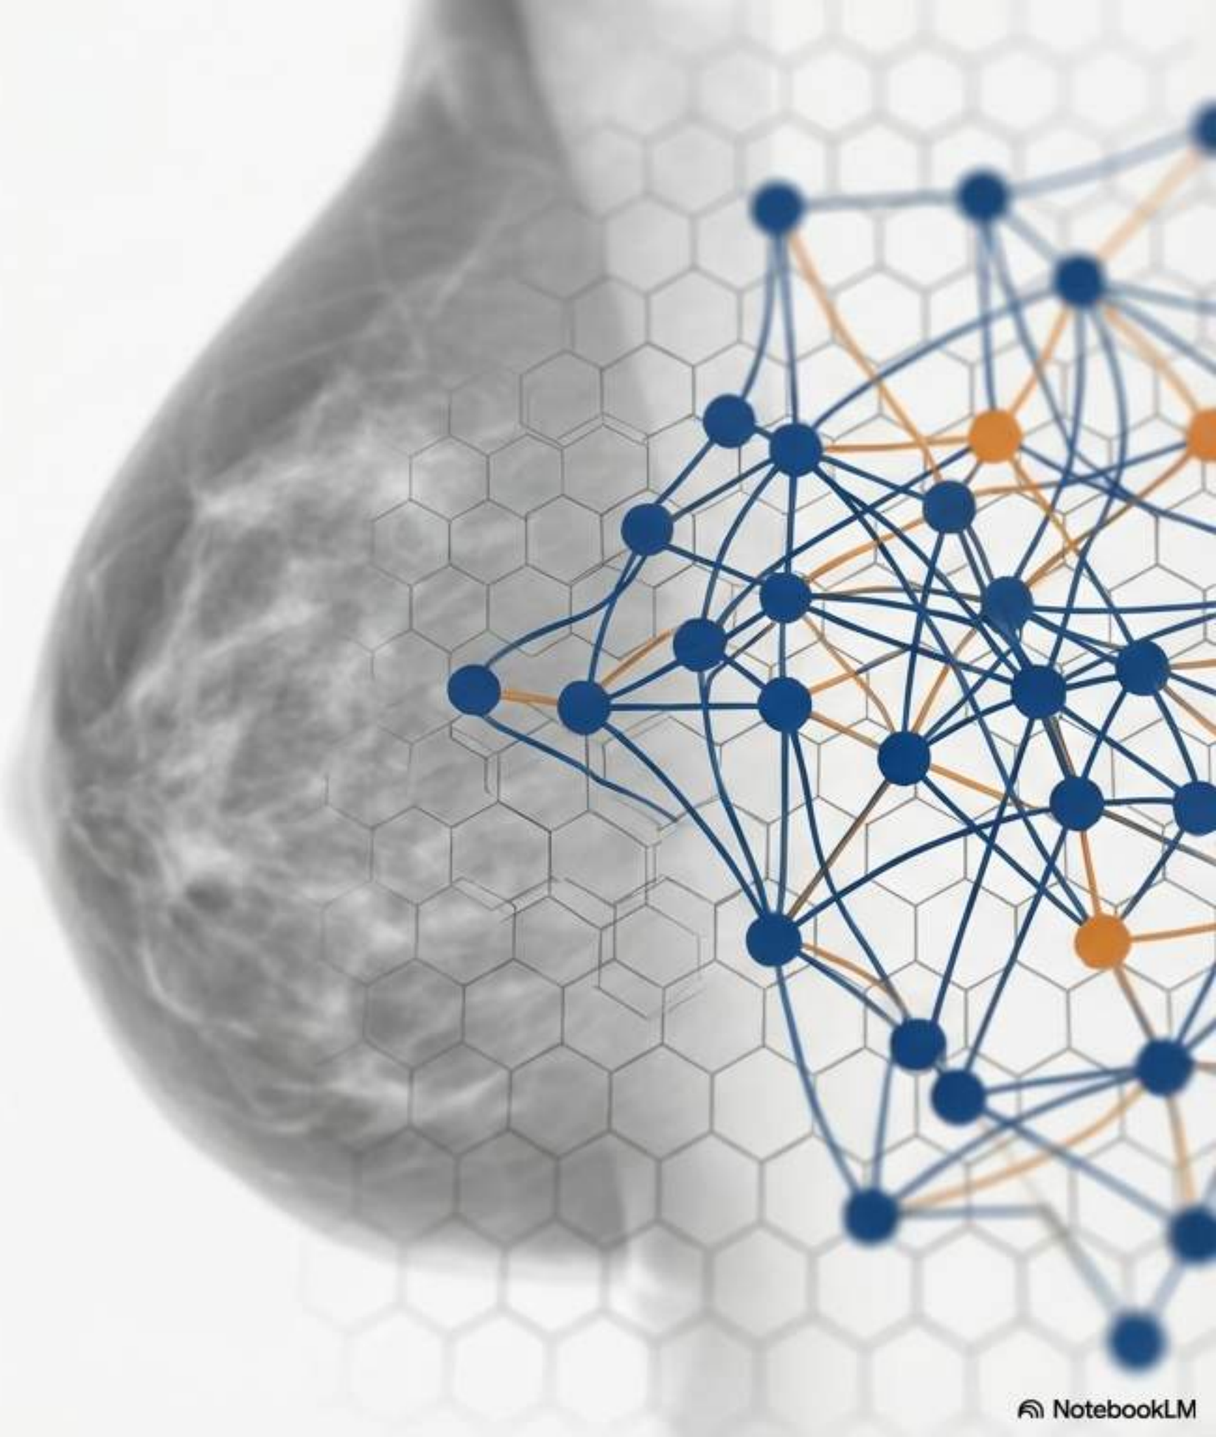

NotebookLM

Filar I: Radiomika – Kwantyfikacja Niewidzialnych Wzorców

Radiomika to proces ekstrakcji dużej liczby ilościowych cech z obrazów medycznych. Te cechy, zwane "radiomicznymi", opisują właściwości guza, takie jak kształt, intensywność i tekstura, które często wykraczają poza możliwości ludzkiej percepcji. Umożliwia to uchwycenie heterogeniczności guza i stworzenie jego unikalnej "sygnatury radiomicznej".
Ten proces przekształca obraz w ustrukturyzowany zbiór danych, który staje się podstawą dla modeli uczenia maszynowego.

- **Cechy pierwszego rzędu (statystyczne):** Opisują rozkład wartości wokseli (np. średnia, wariancja, skośność, kurtoza).
- **Cechy drugiego rzędu (teksturalne):** Analizują przestrzenne zależności między wokselami (np. z macierzy współwystępowania GLCM, macierzy długości serii GLRLM). Cechy takie jak Contrast, Correlation, Energy, Homogeneity.
- **Cechy wyższego rzędu:** Wykorzystują filtry (np. falkowe, Laplasjan Gaussa - LoG) do analizy na różnych skalach.

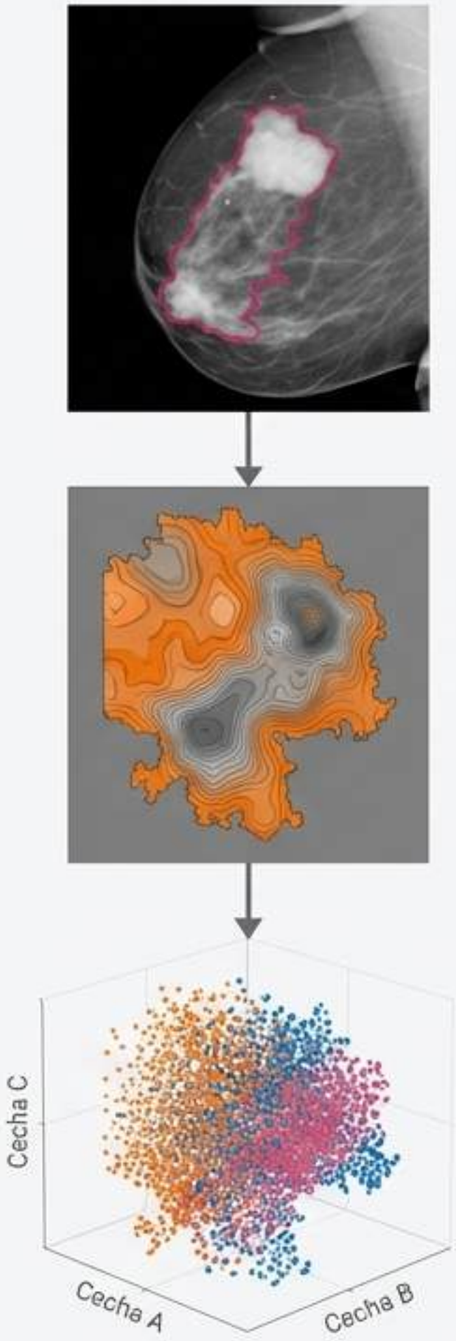

NotebookLM

Filar II: Uczenie Maszynowe – Klasyfikacja w Oparciu o Cechy Radiomiczne

Po ekstrakcji cech radiomicznych, klasyczne algorytmy uczenia maszynowego są trenowane, aby odróżnić zmiany łagodne od złośliwych. Modele te uczą się wzorców na podstawie dostarczonych danych i podejmują decyzje klasyfikacyjne. Wybór odpowiedniego algorytmu i zestawu cech jest kluczowy dla osiągnięcia wysokiej skuteczności.

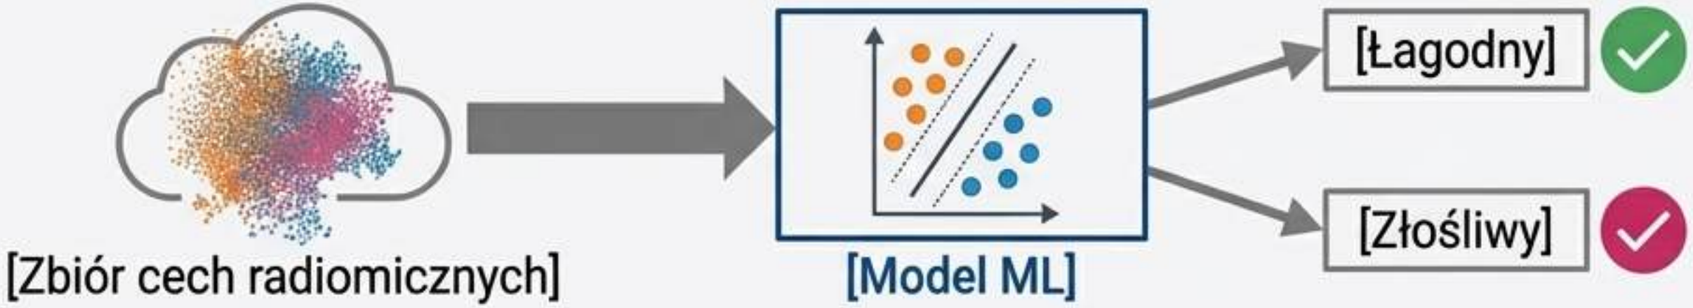

Porównanie kluczowych algorytmów (na podstawie analizy danych CEM)

Algorytm	Najważniejsze Cechy	Skuteczność (ACC)	AUC
Drzewa Decyzyjne (DT)	MAD, VARIANCE, LRLGE	**75%**	0.82
Sieci Neuronowe (NNET)	10 cech z widoku MLO	**77%**	0.83
Maszyny Wektorów Wsparcia (SVM)	**Wszystkie projekcje (CC+MLO)**	**87%**	**0.90**

Wniosek: Analiza wielowymiarowa (multivariate) z wykorzystaniem cech z wielu projekcji i zaawansowanych klasyfikatorów, jak SVM, znacząco przewyższa analizę pojedynczych cech.

NotebookLM

Studium Przypadku: Siła Decyzji Zespołowej w Random Forest

Random Forest (RF) to algorytm zespołowy (ensemble learning), który buduje wiele drzew decyzyjnych podczas treningu i agreguje ich predykcje. Każde drzewo jest trenowane na losowej próbce danych, co redukuje ryzyko przeuczenia i zwiększa stabilność modelu. RF jest szczególnie skuteczny w analizie danych medycznych ze względu na jego odporność na szum i zdolność do identyfikacji kluczowych predyktorów.

Kluczowe zalety RF

- Wysoka dokładność i stabilność.
- Wbudowany mechanizm oceny ważności cech.
- Odporność na nadmierne dopasowanie (overfitting).

Wyniki w praktyce

W badaniach klasyfikacyjnych na publicznym zbiorze danych Breast Cancer Wisconsin, modele oparte na Random Forest osiągnęły imponującą dokładność klasyfikacji na poziomie **96.78%**, przewyższając wiele innych implementacji. W innym badaniu, model RF oparty na cechach radiomicznych CE-CBBCT osiągnął najwyższą zdolność predykcyjną (AUC = **0.806** w zbiorze testowym) w porównaniu do pięciu innych algorytmów ML.

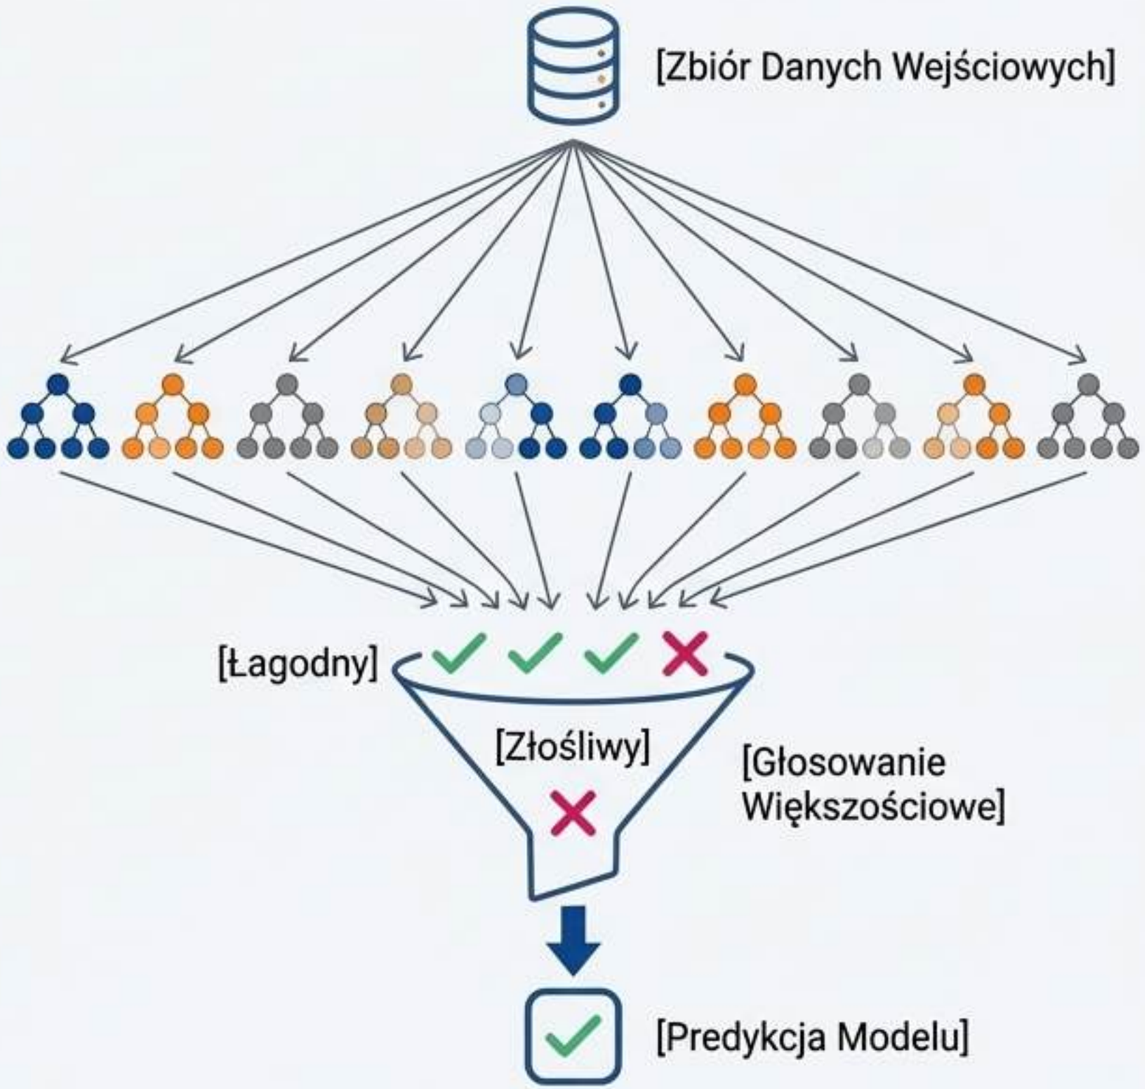

NotebookLM

Filar III: Uczenie Głęokie – Automatyczne Odkrywanie Hierarchii Cech

Uczenie głębokie, w szczególności Konwolucyjne Sieci Neuronowe (CNN), stanowi zmianę paradygmatu. Zamiast polegać na ręcznie projektowanych cechach radiomicznych, modele CNN uczą się hierarchii cech bezpośrednio z surowych pikseli obrazu. Wczesne warstwy sieci identyfikują proste wzorce, takie jak krawędzie i tekstury, podczas gdy głębsze warstwy składają je w bardziej złożone, abstrakcyjne reprezentacje, takie jak kształty i struktury charakterystyczne dla zmian złośliwych.

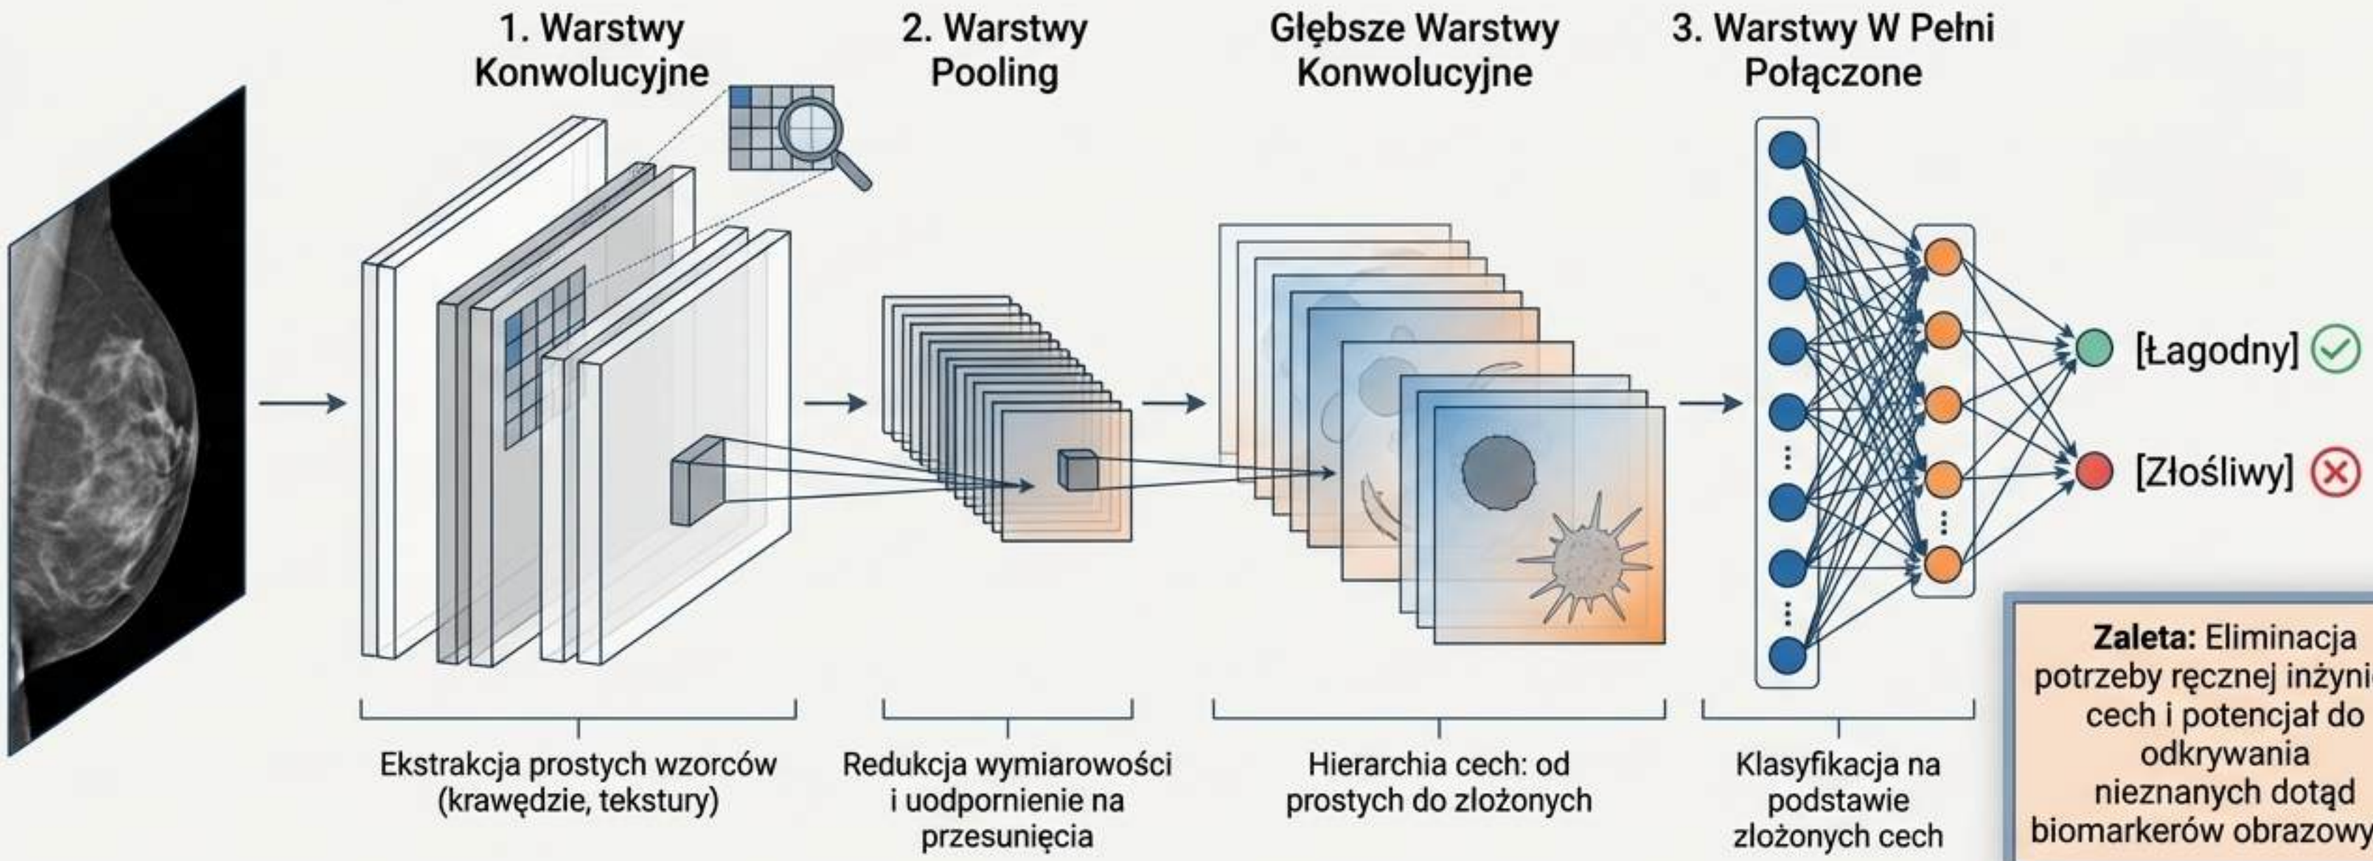

Zaleta: Eliminacja potrzeby ręcznej inżynierii cech i potencjał do odkrywania nieznanych dotąd biomarkerów obrazowych.

NotebookLM

Zastosowanie Transfer Learning: Wyniki Gotowych Architektur CNN

Trening głębokich sieci neuronowych od zera (denovo) wymaga ogromnych zbiorów danych. Transfer learning (TL) to technika, w której model wstępnie wytrenowany na dużym, ogólnym zbiorze danych (np. ImageNet) jest adaptowany do specyficznego zadania medycznego. Pozwala to wykorzystać wiedzę o podstawowych cechach wizualnych (krawędzie, tekstury) i dostroić jedynie ostatnie warstwy sieci do klasyfikacji obrazów mammograficznych mammograficznych.

Wyniki eksperymentalne na zbiorze CBIS-DDSM: Porównanie dokładności (accuracy)

Model	Optimizer	Learning Rate	Accuracy	Loss
VGG16	Adam	0.001	70%	1%
ResNet50	Adam	0.01	69%	5%
DenseNet121	**Adam**	**0.01**	**80%**	**2%**
InceptionResnet	Adam	0.01	60%	6%

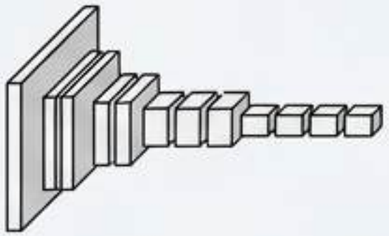

VGG16

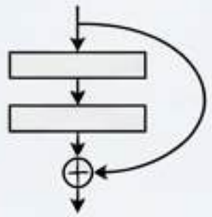

ResNet50

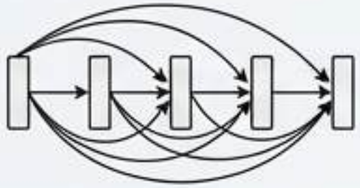

DenseNet121

Wniosek: Wyniki transfer learningu są obiecujące i stanowią dobry punkt wyjścia, jednak złożoność architektur wytrenowanych na tysiącach klas może być suboptymalna dla binarnego problemu klasyfikacji raka piersi. Najlepsze wyniki osiągnął model DenseNet121 (80% accuracy).

NotebookLM

Synteza: Modele Hybrydowe – Synergia Cech Głębokich i Ręcznie Projektowanych

Najwyższą skuteczność diagnostyczną osiąga się nie przez wybór jednej metody, ale przez ich inteligentne połączenie. Modele hybrydowe integrują abstrakcyjne cechy automatycznie wyodrębnione przez sieci CNN z precyzyjnymi, ręcznie projektowanymi cechami (handcrafted features), które niosą ze sobą wiedzę domenową ekspertów. Takie podejście łączy zdolność maszyn do odkrywania ukrytych wzorców z dekadami wiedzy klinicznej.

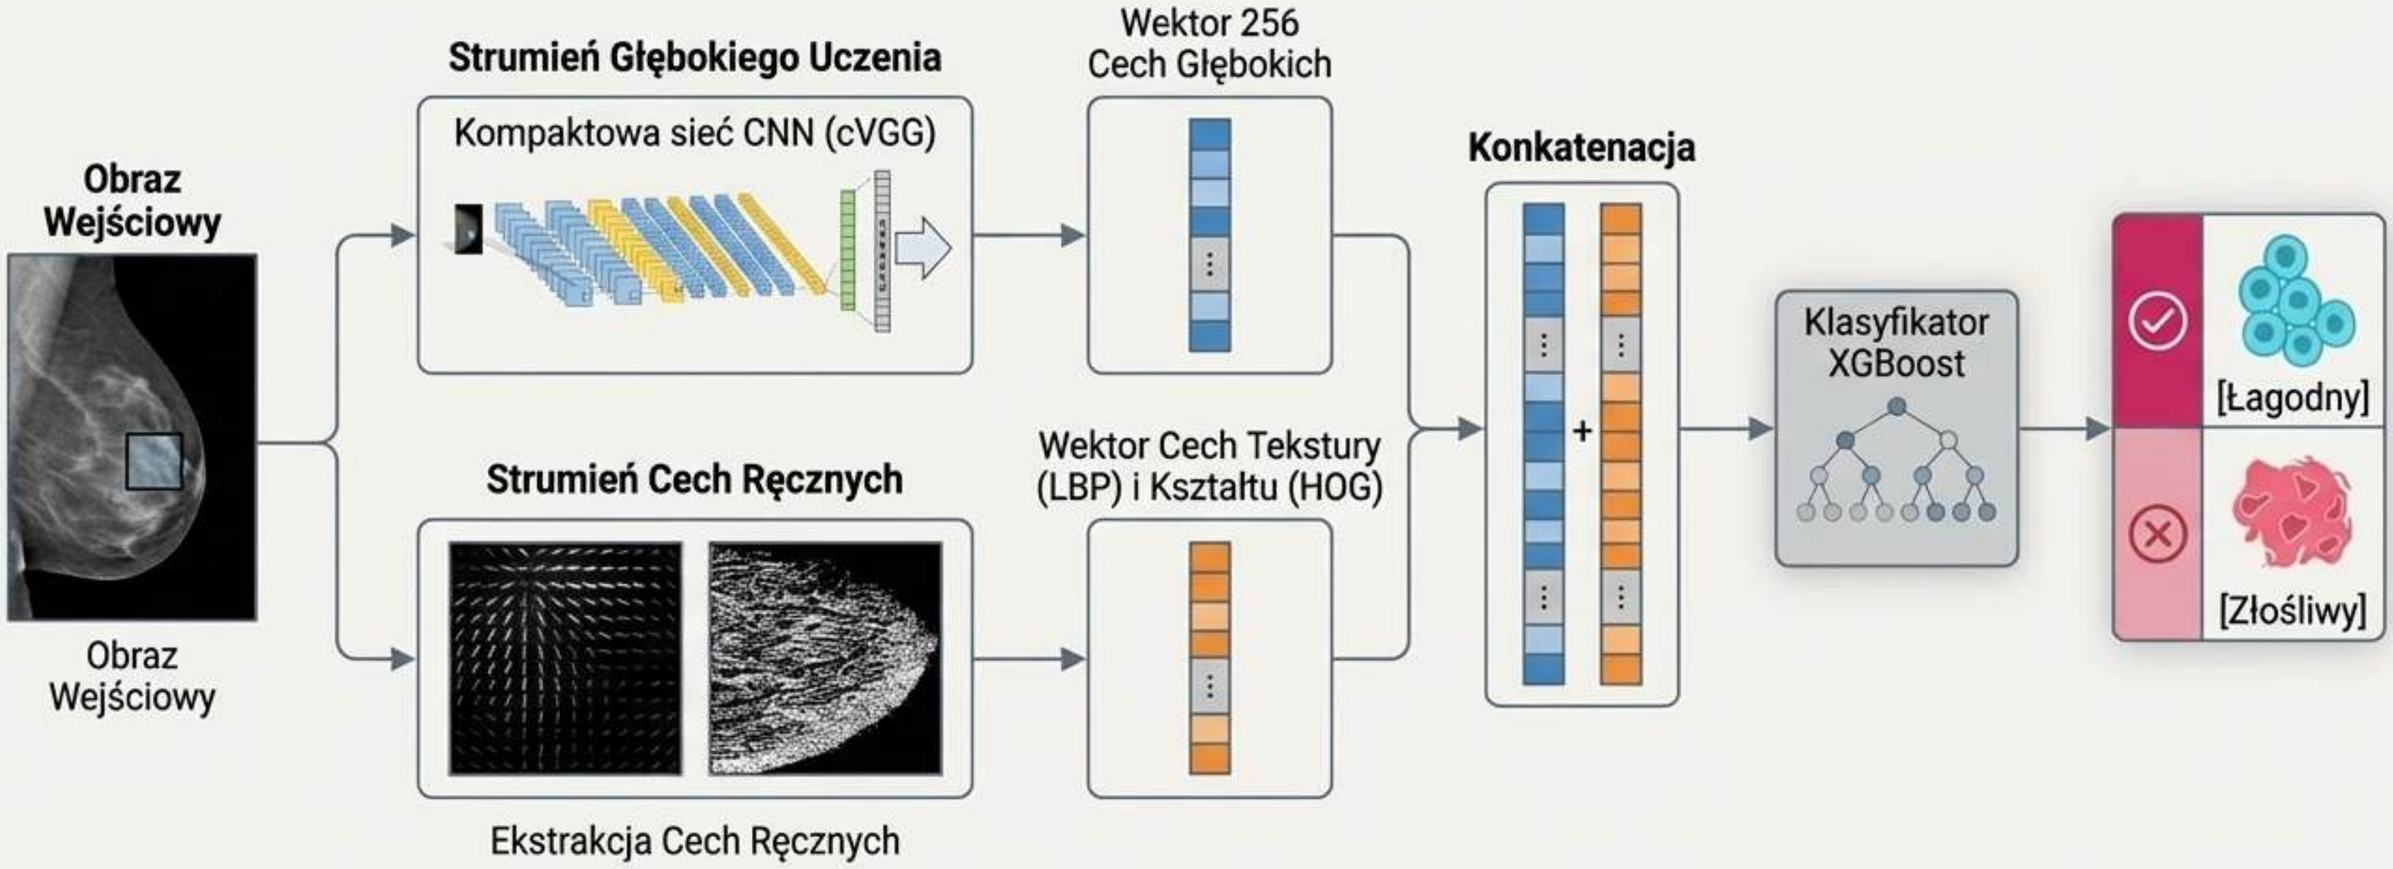

NotebookLM

Przełom w Skuteczności: Wyniki Modelu Hybrydowego

Połączenie cech głębokich z cechami ręcznie projektowanymi prowadzi do skokowego wzrostu dokładności klasyfikacji. Ewaluacja na zbiorze danych CBIS-DDSM wykazała, że model hybrydowy, w połączeniu z zaawansowanym klasyfikatorem, znacząco przewyższa zarówno modele oparte wyłącznie na transfer learningu, jak i te wykorzystujące tylko jeden rodzaj cech.

Technika	Najlepszy Klasyfikator	Dokładność
Transfer Learning (Baseline)	DenseNet121	80%
Tylko Cechy Głębokie (z cVGG)*	XGBoost	60%
Model Hybrydowy (Cechy Głębokiej + HOG/LBP)	**XGBoost**	**91.5%**

*Wyniki dla cech głębokich używanych w izolacji.

Kluczowe obserwacje

- Samodzielnie, cechy głębokie z nowej, kompaktowej sieci nie osiągają wysokiej skuteczności, co podkreśla wyzwania w treningu na ograniczonych danych.
- Dopiero połączenie ich z informacjami o teksturze (LBP) i kształcie (HOG) pozwala na osiągnięcie synergii i skokowej poprawy wyników.
- Klasyfikator **XGBoost** okazał się najskuteczniejszy w analizie połączonego, wielowymiarowego wektora cech, osiągając **91.5%** dokładności.

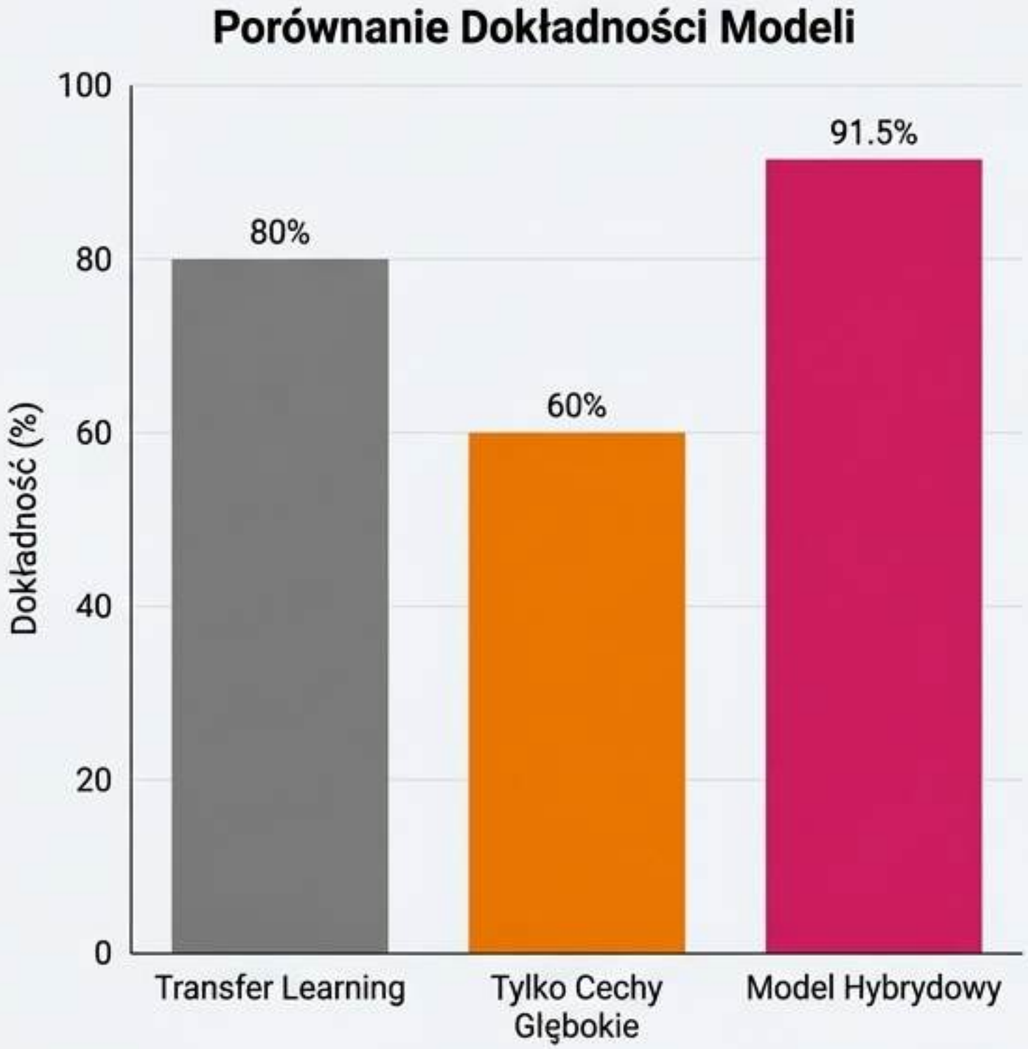

NotebookLM

Podsumowanie Ewolucji i Kluczowe Wnioski

Jesteśmy świadkami rewolucji w **diagnostyce obrazowej raka piersi**, napędzanej przez synergię danych i algorytmów. Nasza podróż przez filary technologiczne AI pokazuje wyraźną ścieżkę postępu:

4. **Modele Hybrydowe** stanowią obecny szczyt ewolucji, łącząc siłę automatyzacji DL z wiedzą ekspercką zawartą w cechach ręcznych, co prowadzi do najwyższej, ponad 91-procentowej dokładności.

3. **Uczenie Głębokie** (CNN) zautomatyzowało proces odkrywania cech, eliminując potrzebę ręcznej inżynierii i otwierając nowe możliwości.

2. **Klasyczne Uczenie Maszynowe** (SVM, RF) udowodniło, że analiza tych danych pozwala osiągnąć wysoką skuteczność (do 87% AUC 0.90 w modelach wieloprojekcyjnych).

1. **Radiomika** stworzyła fundament, przekształcając obrazy w obiektywne dane.

Główny Wniosek: Przyszłość należy do zintegrowanych, multimodalnych systemów CAD, które wykorzystują komplementarne informacje z różnych źródeł i metod, aby wspierać klinicystów w podejmowaniu precyzyjnych i spersonalizowanych decyzji.

NotebookLM

Perspektywy: W Kierunku Zintegrowanej i Wyjaśnialnej Diagnostyki AI

Rozwój zaawansowanych modeli AI to dopiero początek. Kluczowymi wyzwaniami na drodze do wdrożeń klinicznych są teraz:

- **Wyjaśnialność (Explainable AI - XAI)**: Budowanie zaufania klinicystów poprzez tworzenie modeli, które potrafią uzasadnić swoje predykcje, np. wskazując na obrazie obszary, które wpłynęły na decyzję. Modele 'czarnej skrzynki' (black-box) stanowią barierę w adopcji.
- **Walidacja i Regulacje**: Konieczność walidacji modeli na dużych, zróżnicowanych, wieloośrodkowych zbiorach danych oraz uzyskanie certyfikacji (np. oznakowanie CE, zgoda FDA) w celu zapewnienia bezpieczeństwa i niezawodności.
- **Integracja Multimodalna**: Łączenie danych nie tylko z różnych projekcji mammograficznych, ale także z różnych modalności obrazowania (MRI, USG, PET) oraz danych histopatologicznych i klinicznych w celu stworzenia kompleksowego, cyfrowego profilu pacjenta.

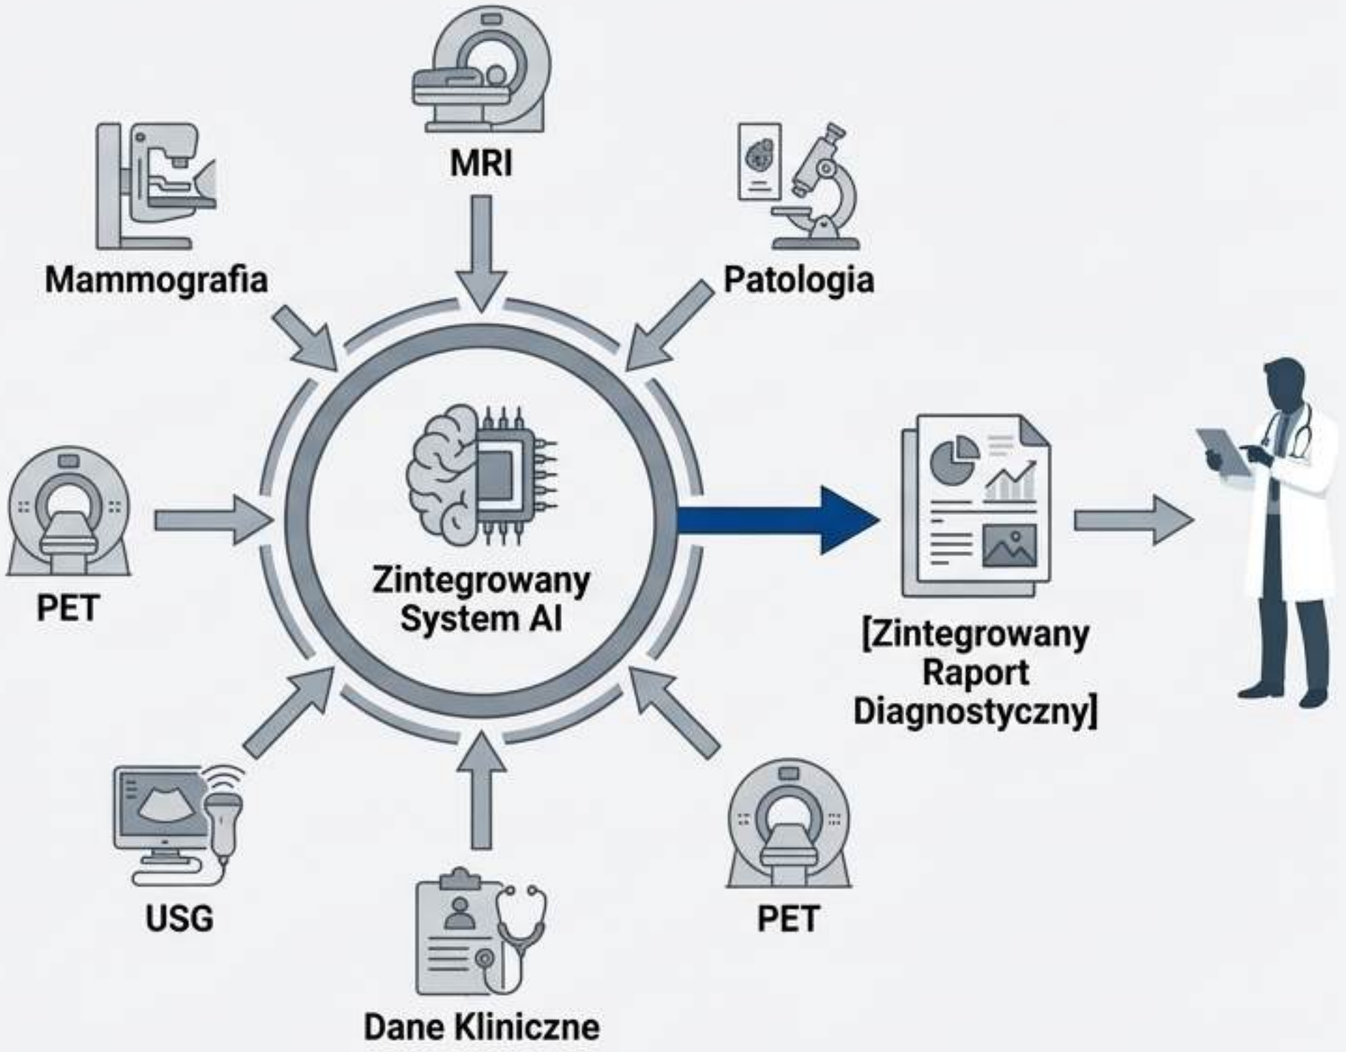

Wizja przyszłości

Stworzenie kompleksowego systemu CAD, który bezproblemowo integruje się ze szpitalnymi systemami informatycznymi, wspierając klinicystów na każdym etapie – od wczesnego wykrywania, przez planowanie leczenia, po precyzyjne prognozowanie ryzyka nawrotu, realizując wizję medycyny spersonalizowanej.

NotebookLM